

Modellazione statistica delle donazioni di sangue nella provincia di Trieste

**Dai GLM agli Hidden Markov Models: un quadro predittivo per la
pianificazione trasfusionale**

2027-06-09

Relatore: Prof. Leonardo Egidi



UNIVERSITÀ DEGLI STUDI DI TRIESTE

DIPARTIMENTO DI SCIENZE ECONOMICHE, AZIENDALI,
MATEMATICHE E STATISTICHE “BRUNO DE FINETTI”

Laurea Magistrale in Scienze Statistiche Attuariali

Modellazione statistica delle donazioni di sangue nella provincia di Trieste

*Dai GLM agli Hidden Markov Models: un quadro predittivo per la
pianificazione trasfusionale*

Relatore:

Prof. Leonardo Egidi

Candidato:

2027-06-09

Indice

Prefazione	9
1 Introduzione	11
1.1 Struttura della tesi	12
1.2 I Dati	12
1.2.1 Fonte ed Elaborazione	14
1.2.2 Analisi Preliminare	16
1.3 Integrazione dei Dati	16
1.3.1 Stima dei Residenti Passati	17
1.3.2 Unione dei Dati	18
2 Modelli Lineari Generalizzati	21
2.1 Teoria dei GLM	21
2.1.1 Regressione Lineare	21
2.1.2 Metodi di stima	23
2.1.3 Estensione della Regressione Lineare	24
2.1.4 Famiglia Esponenziale	24
2.2 Modelli GLM	26
2.2.1 Quasi-Poisson	26
2.2.2 Tweedie	27
2.2.3 Poisson troncata a zero	30
2.2.4 Binomiale Negativa	31
2.2.5 Performance	32
2.3 Modello Temporale	33
3 Bayesian Hidden Markov Models	37
3.1 Accenni di Teoria	37
3.1.1 Processo Markoviano	37
3.1.2 Hidden Markov Models (HMM)	39
3.1.3 Bayesiana	40
3.1.4 Teoria dell'algoritmo di Viterbi (caso generale)	41
3.2 Il modello applicato alle donazioni	42
3.2.1 Pyro	42
3.2.2 Dati e covariate	43
3.2.3 Componenti del Modello	46
3.3 Risultati	51
3.3.1 Coefficienti β_{em}	53
3.3.2 Coefficienti W_{π}	54
3.3.3 Coefficienti W_A	54

3.4	Algoritmi e diagnostiche	55
3.4.1	Viterbi con covariate	55
3.4.2	Forward per log-likelihood	56
3.4.3	Calibrazione e confronto con GLM	58
4	Dashboard e Sito Web	63
4.1	Motivazione	63
4.2	Sviluppo	63
5	Conclusioni	65
5.1	Risultati	65
5.2	Idee per il Futuro	65
	Riferimenti	67

Elenco delle Figure

1.1	Distribuzioni dei donatori per genere ed età nel 2009 e nel 2023	16
1.2	Distribuzione del tasso di donatori tra i residenti per anno, età e genere	19
2.1	Risultati del modello Quasi-Poisson	27
2.2	Risultati del <i>grid searching</i> per p	29
2.3	Coefficienti del modello di Poisson troncato in zero	31
2.4	Residui del modello negativo binomiale	32
2.5	Effetti del modello predittivo con ritardi integrati	35
3.1	Log-likelihood e BIC al variare del numero di parametri	50
3.2	Risultati principali del modello	52
3.3	Grafici sui valori dei coefficienti W_π	54
3.4	Coefficienti di W_A	55
3.5	Occupazione degli stati per anno	56
3.6	Predizione del numero di donazioni per diversi profili di donatore . .	59

Prefazione

La tesi si propone di analizzare a fondo un problema reale: le donazioni di sangue. A causa dell'ambito sanitario, i dati sono decisamente scarni, non in quantità ma in informazione che portano. Sarà dunque il compito di questo elaborato sfruttare e massimizzare al massimo i dati a nostra informazione. La ricerca si focalizzerà su specifici modelli statistici ed analizzerà a fondo le loro capacità e le loro estensioni.

Consiglio

L'elaborato è usufruibile in versione PDF, epub e web. Per una visione migliore si consiglia l'utilizzo della versione web, dove, oltre alla tesi, saranno presenti anche i *notebook* che l'autore ha usato per fare le analisi preliminari e la costruzione dei modelli; le diapositive (in formato HTML) della discussione di tesi e dell'esame di *Probabilistic Machine Learning*; e una dashboard per la messa in produzione del lavoro fatto.

Buona Lettura!

1 Introduzione

L'obiettivo di questa tesi è proporre — e validare empiricamente — un framework statistico per la previsione delle donazioni di sangue nel territorio Giuliano-Isontino, con orizzonte annuale.

La scelta di concentrare l'analisi sulla provincia di Trieste è motivata da tre fattori:

1. **Alta densità di donatori rispetto alla popolazione residente:** il territorio triestino è storicamente virtuoso nella raccolta di sangue; ciò rende disponibili serie temporali lunghe e relativamente complete.
2. **Stabilità del bacino d'utenza:** la popolazione residente ha oscillazioni demografiche contenute, riducendo la variabilità “esterna” dovuta a migrazioni massicce. A differenza di grandi città, come Milano e Roma dove i flussi migratori sono hanno un impatto maggiore.
3. **Accesso a dati granulari:** l'ASUGI ha messo a disposizione un estratto anonimo dei registri donatori 2009-2023 che, pur privo di variabili sensibili, contiene informazioni anagrafiche e cronologia donativa sufficienti per la modellazione.

Nella pratica quotidiana i centri trasfusionali devono rispondere alla domanda clinica garantendo un buffer di scorte: sovrastimare i lotti in scadenza comporta costi di smaltimento, mentre sottostimare la raccolta può generare situazioni critiche con rinvii di interventi chirurgici programmati.

Pertanto, è cruciale disporre di **strumenti predittivi** che stimino:

- la probabilità che un donatore torni a donare l'anno successivo;
- la distribuzione del numero di donazioni attese per singolo individuo;
- i profili latenti di comportamento (frequente, saltuario, non-donatore, ecc.) e la loro evoluzione nel tempo.

A fronte di tali esigenze la tesi si articola in due nuclei metodologici:

1. **Generalized Linear Models (GLM)** per stimare il numero *cumulato* di donazioni nell'orizzonte storico, con diverse famiglie di distribuzione (quasi-Poisson, Tweedie, Gamma).

2. **Hidden Markov Models bayesiani** con covariate, in cui il numero di donazioni annue è trattato come emissione di una variabile di stato latente.

Il fitting è condotto mediante Variational Inference (Pyro), consentendo di gestire milioni di osservazioni con tempi computazionali compatibili al problema.

A corredo dei modelli è stata sviluppata una **dashboard interattiva Quarto + Shiny** che consente al personale medico di:

- filtrare la popolazione (età, genere, anno di prima donazione, ecc.);
- visualizzare la probabilità di transizione fra stati latenti;

1.1 Struttura della tesi

La tesi è strutturata in 6 capitoli:

1. il primo, ovvero il seguente, introduce la tesi e descrive la parte preliminare di analisi e pulizia del dato. Parte fondamentale per i capitoli successivi;
2. la seconda parte, introduce i modelli lineari generalizzati, analizzandoli dal punto di vista teorico e pratico. Il capitolo analizzerà diverse distribuzioni applicate sempre allo stesso modello, mettendo in luce pregi e difetti di ciascuna di esse;
3. il terzo capitolo è il nucleo della tesi, si andrà a costruire il modello finale del progetto, una combinazione tra elementi diversi, infatti si userà un modello markoviano a stati latenti con dei modelli lineari generalizzati sulle emissioni e usando un approccio bayesiano sulle probabilità iniziali e la matrice di transizione;
4. il quarto, si dedicherà alla parte pratica del progetto, la messa in produzione del modello. Descriverà il processo di costruzione di una dashboard per permettere al personale medico l'usufruzione del modello in tempo reale;
5. l'ultimo capitolo raccoglierà le somme del progetto, mettendo in luce i punti di forza e i talloni d'achille del progetto. Inoltre, si analizzeranno idee future per ulteriori implementazioni e approfondimenti.

1.2 I Dati

La raccolta dati, come già anticipato, è fondamentale per poter elaborare un framework statistico a supporto dei strumenti predittivi e questi dati è possibile raccogliarli grazie a tutto il sistema che ruota attorno al processo della donazione di sangue. Per poter donare il sangue in Italia c'è appunto un sistema di stakeholder del settore pubblico (regioni, centri ospedalieri), privato (associazioni non profit) e

cittadini che contribuiscono attivamente al buon esito di questo processo (Guglielmetti Mugion et al. (2021)). La creazione del [Centro Nazionale Sangue](#) (CNS) e del Registro nazionale del sangue nel 2007 ha trasformato l'assetto organizzativo della donazione del sangue in Italia. Il CNS è stato istituito con Decreto del Ministro della Salute del 26 aprile 2007 e ha iniziato il suo mandato il 1° agosto dello stesso anno. Il CNS svolge funzioni di coordinamento e controllo tecnico-scientifico del sistema trasfusionale nazionale nelle materie disciplinate dalla legge n. 219 del 21 ottobre 2005 “Nuova disciplina delle attività trasfusionali e della produzione nazionale degli emoderivati” e dai decreti di trasposizione delle direttive europee. All'interno di tale sistema sono presenti le Strutture Regionali di Coordinamento per le attività trasfusionali (SRC). Le SRC sono strutture tecnico-organizzative delle Regioni e Province Autonome che garantiscono il supporto alla programmazione nazionale in materia di attività trasfusionali e il coordinamento e controllo tecnico-scientifico della rete trasfusionale regionale, in sinergia con il Centro Nazionale Sangue. Queste strutture regionali, anche definite Centri Regionali Sangue, detengono la responsabilità della raccolta e gestione delle donazioni di sangue a livello regionale (Bordandini (2025)). Dopo le riforme degli anni novanta (D.Lgs. 502/92 e 517/93) c'è stato un importante riassetto del sistema sanitario nazionale con uno spostamento della gestione verso le Regioni. In Friuli Venezia Giulia con la Legge Regionale 22/2019 viene riordinato il Sistema Sanitario Regionale dove a seguito di un decreto attuativo il 1° gennaio 2022 viene istituita l'[Azienda Sanitaria Universitaria Giuliano Isontina](#) (ASUGI) dalla quale attingeremo la maggior parte dei dati per l'elaborazione della nostra tesi.

Il campione statistico che andremo ad analizzare è quello dei donatori di sangue che in Italia è rappresentato dalle persone che possono donare e più precisamente con un'età compresa tra i 18 e i 65 anni, con un peso corporeo superiore ai 50 kg e in buono stato di salute. Gli uomini e le donne non in età fertile possono donare sangue intero ogni 3 mesi, mentre le donne in età fertile possono farlo 2 volte l'anno.

A livello quantitativo ci troviamo di fronte ad un elevato numero di donatori, circa 1,7 milioni nel 2024 (Nomisma (2024)). Ciò è dovuto anche grazie alle attività di supporto offerta dalle associazioni attive nel campo delle donazioni, come AVIS (Associazioni Volontari Italiani Sangue), FRATRES (Consociazione Nazionale dei Gruppi Donatori di Sangue Fratres delle Misericordie d'Italia), FIDAS (Federazione Italiana Associazioni Donatori di Sangue), Croce Rossa Italiana. Queste organizzazioni svolgono un ruolo cruciale nel promuovere attivamente la pratica della donazione del sangue: sebbene la decisione di donare sia una scelta individuale, è infatti importante sottolineare il ruolo essenziale che esse svolgono nell'informare e nel fungere da ponte tra le istituzioni (scuole incluse) e i cittadini (Bordandini (2025)). Attraverso diversi studi, analizzati dalla Bordandini, è stato possibile definire come fondamentale il lavoro svolto dalle diverse associazioni appena citate, per l'incremento di capitale sociale sia costruendo relazioni con le istituzioni locali, sia creando partecipazione e attivazione attraverso diverse iniziative che mirano allo sviluppo di senso di comunità e appartenenza (Saturni, Fiorentini, e Ricciuti (2017)). È stato visto che agevolazioni quali la Legge 584 del 1967, che ha stabilito il riconoscimento del diritto a una giornata di riposo dal lavoro e alla piena retribuzione al donatore di sangue, piuttosto che lo stesso riconoscimento sociale motivato dal

confronto con amici e familiari, ma anche l’aver ricevuto trasfusioni o conoscere qualcuno che ha beneficiato di una trasfusione hanno avuto un impatto significativo, aumentando la frequenza delle donazioni e la propensione a persuadere altri a donare(Bordandini (2025)).

A fronte di quanto appena esposto, ai fini dei strumenti predittivi oggetto di questa tesi, è importante tenere conto delle variabili che andremo di seguito ad analizzare.

1.2.1 Fonte ed Elaborazione

Tabella 1.1: Variabili presenti nel dataset fornito dal centro trasfusionale

campo	descrizione
donor_class	classificazione del donatore
donation_type	categoria (SANGUE, PLASMA, PIASTRINE, ...)
birth_year	anno di nascita
birth_cohort	coorte di nascita, generazione (1970, 1975, 1980, ...)
first_donation_year	anno della prima donazione registrata
first_donation_cohort	coorte della prima donazione registrata
number of donations	numero di donazioni effettuate nel determinato anno
gender	M/F
year	anno di riferimento delle donazioni
age	età del donatore
unique_number	identificativo anonimo del donatore

I dati provengono dall’estrazione e anonimizzazione di dati provenienti dal data warehouse dell’Azienda Sanitaria Universitaria Giuliano Isontina (ASUGI). I dati vengono forniti in formato Il dataset primario proviene dal sistema informativo dei centri trasfusionali dell’ASUGI e contiene le donazioni fatte da un individuo in un determinato anno, corredate di ulteriori informaizioni, riportate nella Tabella 1.1.

donor	donation	birth	birth	first	first	number				unique
class	type	year	cohort	donation	donation	of	gender	year	age	number
P	ANGUE	1981	1980	2010	2010	1	F	2020	39	26964930
P	ASMAF	1975	1975	2010	2010	9	M	2015	40	26942475
P	ANGUE	1952	1950	1979	1975	3	M	2009	57	26488500
P	PLASM	1972	1970	2012	2010	1	F	2017	45	26992638
P	ASMAF	1972	1970	1995	1995	3	F	2012	40	26526780
P	PLASM	1966	1965	1993	1990	3	M	2019	53	26488377
P	LTAFE	1976	1975	2002	2000	1	M	2011	35	26759793
P	LTAFE	1977	1975	2009	2005	3	F	2014	37	26939493

Tabella 1.2: Campione di dati grezzi forniti dal centro trasfusionale

Anche se i dati provengono da un datawarehouse che rispetta protocolli nella gestione del dato, è comunque necessaria una fase di *ETL* (Extract, Transform, Load). Ovvero l'estrazione e la trasformazione del dato in modo da adattarlo e arricchirlo ai nostri scopi specifici. Il lavoro viene svolto mediante il linguaggio di programmazione statistica R, e la libreria `tidyverse`, una libreria contenente funzioni per la manipolazione dei dati garantendo leggibilità del codice e velocità d'esecuzione.

La tabella originale è composta da 268.530 righe, una per ogni donatore e per ogni anno nella quale abbia donato. Tuttavia sono presenti record duplicati (171.378).

I passi principali compiuti sono i seguenti:

- rimozione record duplicati (`janitor::get_dupes`);
- sostituzione di NA con 0 nei conteggi annuali;
- derivazione di $\text{età} = \text{year} - \text{birth_year}$ e classi d'età quinquennali;
- standardizzazione (z-score) di `birth_year` e `age` per facilitare la convergenza dell'ottimizzatore nei modelli bayesiani;
- aggiunta della variabile dummy Covid;
- creazione di **tre matrici di covariate**:
 - x^π (fisse per donatore): anno di nascita e genere;
 - x_t^A (tempo-varianti): età categorica e dummy Covid;
 - x_t^{em} (tempo-varianti): età categorica, dummy Covid e genere.

La derivazione dell'età sarà utile per avere una variabile dinamica, che varia nel tempo. Infatti si presuppone che la propensione al donare vari con l'età del donatore, ed avendo osservazioni pluriennali, si ritiene opportuno tenere in considerazione ciò. Però, anche il fattore generazionale può influire, ovvero una persona di 50 anni del 1970 può avere una propensione nel donare diversa di un cinquantenne nato 10 anni prima. Questo potrebbe essere dovuto da fattori generazionali e anch'esso andrà incluso nelle analisi. Infine, in molte analisi condotte, è stata utilizzata la variabile età come categoriale, anziché numerica.

Nei primi 10 giorni di marzo 2020, all'inizio della pandemia SARS-CoV-2, le donazioni di sangue in Italia sono state quasi nulle, per poi passare ad un forte aumento. Il Centro Nazionale Sangue (CNS), l'autorità nazionale competente, pubblicò linee guida chiare per permettere la continuazione dei prelievi di sangue ed evitare un'interruzione della catena di approvvigionamento della raccolta di materiale trasfusionale. (Pati et al. 2021)

Infine, le osservazioni vengono aumentate, ossia vengono aggiunte le donazioni pari a 0 negli anni in cui non abbiamo il dato di uno specifico donatore. Si ipotizza che quando il dato non venga raccolto non ci siano donazioni da parte dell'individuo. Questa è un'ipotesi forte, infatti ci potrebbero essere diverse ragioni per la mancanza del dato e non solo la mancata donazione. Ad esempio, l'individuo si sarebbe potuto

trasferire, o avrebbe potuto decidere di donare in un centro trasfusionale differente da quello da noi analizzato, ossia il centro trasfusionale dell'ASUGI.

1.2.2 Analisi Preliminare

L'Italia, come molti altri paesi del mondo, è affetta dal fenomeno generazionale del *baby boom*, ovvero da un notevole incremento delle nascite negli anni 50-60, dovuto a vari fattori, tra cui la forte crescita economica. Questo fenomeno è oggetto di studio in diversi ambiti, uno tra i quali è l'ambito assicurativo, dove ci si preoccupa se le generazioni più giovani saranno in grado di sopportare il sistema pensionistico quando i *baby boomers* andranno in pensione. Lo stesso discorso vale per le donazioni di sangue, in quanto i donatori saranno meno e coloro che necleriteranno di sacche di sangue sarà sempre maggiore. Questo fenomeno generazionale si può osservare dalla Figura 1.1 dove si osserva uno spostamento nella “gobba” verso l'alto dal 2009 al 2023. Le donazioni provengono maggiormente dagli uomini, tuttavia si osserva (vedi Tabella 1.3) come questo gap si stia riducendo nelle nuove generazioni, grazie anche alla efficace comunicazione dei centri di trasfusione.




Figura 1.1: Distribuzioni dei donatori per genere ed età nel 2009 e nel 2023

1.3 Integrazione dei Dati

Le analisi eseguite finora sono state condotte sui donatori e le loro donazioni, mostrandoci caratteristiche e pattern fondamentali sulle donazioni. Tuttavia, per un'analisi più approfondita è necessario tenere in considerazione anche quella parte

	F		M	
	2009	2023	2009	2023
[18,25]	713	801	959	886
(25,35]	544	570	1420	1125
(35,45]	649	419	2025	1020
(45,55]	505	614	1463	1508
(55,65]	290	339	637	864
(65,70]	2	15	17	27

Tabella 1.3: Donazioni nel 2009 e 2023 per fasce d'età e per genere

di popolazione che non dona, e che, di conseguenza, non risulta essere presente nei dati a noi disponibili.

L'obiettivo è di integrare il database che possediamo con ulteriori informazioni che potrebbero arricchire le analisi e aggiungere informazioni ai modelli.

I dati in nostro possesso sono la raccolta delle donazioni presso le strutture sanitarie dell'ASUGI, ovvero dell'Azienda Sanitaria Universitaria Giuliano Isontina, ovvero che i dati in nostro possesso provengono dai centri trasfusionali del territorio di Trieste e Gorizia. Tuttavia, ciò non indica che le donazioni provengano da cittadini residenti nel territorio Giuliano-Isontino. Infatti, le donazioni sono aperte a tutti, anche a cittadini stranieri, come potrebbe essere uno studente durante il suo progetto Erasmus a Trieste. Andranno fatto, quindi, delle assunzioni per semplificare la realtà. Si ipotizza che le donazioni provengano solo da residenti del territorio. Possiamo allora integrare i dati con le informazioni sui residenti.

Le informazioni provengono dal database pubblico dell'Istituto Nazionale di Statistica, ISTAT. I dati in formato tabulare contengono informazioni di vario genere, tra cui il genere, l'anno, la popolazione e lo stato civile. I dati vengono quindi processati e adattati ai dati sulle donazioni di sangue.

1.3.1 Stima dei Residenti Passati

L'ISTAT diffonde serie complete per il 2019–2023, mentre il nostro dataset copre il periodo a partire dal 2009. Per ricostruire a ritroso la popolazione residente nel capoluogo giuliano adottiamo un approccio in due passi. Primo, richiamiamo l'identità di bilancio demografico, che regola l'evoluzione della popolazione residente (cfr. ISTAT (2023a)):

$$P_t = P_{t-1} + N_t - M_t + I_t - E_t \quad (1.1)$$

dove P_t è la popolazione a fine anno t , N_t i nati vivi, M_t i decessi, I_t gli iscritti per migrazione ed E_t i cancellati per migrazione.

Per ricostruire a ritroso la popolazione residente nel capoluogo giuliano (2009–2018) adottiamo il metodo di retroproiezione per coorti (“reverse life-table”), che utilizza i sopravvissuti l_x dalle tavole di mortalità per risalire alla consistenza delle coorti alle età precedenti (cfr. Caselli, Vallin, e Wunsch (2006); per definizioni e stima di l_x nelle tavole ISTAT si veda ISTAT (2023b)). La formulazione operativa impiegata è:

$$n_x^{y_i} = n_{x-(y_i-y_j)}^{y_j} \frac{l_x}{l_{x-(y_i-y_j)}}, \quad (1.2)$$

dove $n_x^{y_i}$ è l’effettivo alla età x al tempo y_i , $n_{x-(y_i-y_j)}^{y_j}$ è l’effettivo della medesima coorte alla età $x - (y_i - y_j)$ osservato (o stimato) al tempo y_j , e il rapporto $\frac{l_x}{l_{x-(y_i-y_j)}}$ rappresenta la probabilità di sopravvivenza tra le due età secondo la tavola di mortalità di riferimento. In mancanza di flussi migratori comunali completi, si assume, in prima approssimazione, migrazione netta nulla o costante e si verifica la robustezza dei risultati tramite analisi di sensitività.

i Nota sulle tavole SIM/SIF 02

Con “SIM/SIF 02” si fa riferimento a una delle serie ufficiali di tavole di mortalità pubblicate da ISTAT, per età singola e per sesso, che riportano le principali funzioni di tavola (in particolare i sopravvissuti l_x , le probabilità q_x , i decessi d_x e gli esposti L_x) e costituiscono la base standard per calcoli di sopravvivenza e retroproiezione a livello nazionale.

1.3.2 Unione dei Dati

La join tra il registro dei donatori e il dataframe con i residenti consente di costruire un indicatore di “penetrazione” (quota di donatori sulla popolazione residente), disaggregato per anno, classe d’età e genere. Indichiamo con $\#donatori(a, y, g)$ il numero di individui presenti nel dataset in quella cella (a, y, g) e con $residenti(a, y, g)$ il denominatore demografico coerente (stessa cella di età, anno e genere). Definiamo quindi:

$$penetration_{a,y,g} = \frac{\#donatori(a, y, g)}{residenti(a, y, g)}, \quad g \in \{F, M\}, a = \text{classe d'età}, y.$$

Nel seguito, per il grafico (Figura 1.2) lavoriamo su età singola, mentre per la tabella (Tabella 1.4) aggregiamo a classi decennali. Si noti che la coerenza del denominatore è garantita dall’integrazione con i residenti ISTAT per la medesima triade (g, y, a) .

Il rapporto tra donatori e popolazione residente permette di analizzare i dati in modo relativo, eliminando differenze nella popolazione, come il fenomeno del *baby boom* osservato in Sezione 1.2.2. Il grafico mostra l’elevato picco che c’è attorno ai 20

	F					M				
	2011	2014	2017	2020	2023	2011	2014	2017	2020	2023
[18,25]	5.36%	5.33%	5.91%	5.42%	6.50%	7.17%	6.70%	6.60%	6.31%	6.17%
(25,35]	2.63%	2.64%	3.08%	3.09%	3.25%	6.17%	5.76%	5.64%	5.51%	5.78%
(35,45]	2.06%	1.87%	1.94%	1.94%	2.15%	6.62%	5.98%	5.80%	5.43%	4.93%
(45,55]	1.85%	1.62%	1.92%	1.95%	2.08%	5.77%	5.07%	5.21%	5.00%	5.13%
(55,65]	1.05%	0.90%	1.09%	1.21%	1.17%	2.63%	2.46%	2.87%	3.09%	3.08%
(65,70]	0.11%	0.13%	0.12%	0.09%	0.14%	0.60%	0.41%	0.33%	0.31%	0.32%

Tabella 1.4: Percentuale di donatori tra i residenti per età e anno

anni, che successivamente va decrescendo, soprattutto nelle femmine. Si evidenzia un trend crescente nella fascia 18-25 delle femmine passando in 12 anni dal 5,36% al 6,5% (+21%), questo trend è ancor più forte per la fascia 25-35 dove la percentuale di donatrici è più che raddoppiata passando dal 2,63% al 5,64%. Per gli uomini si osserva, invece, un leggero calo nel rapporto tra donatori e popolazione negli ultimi che, però, rimangono in termini assoluti e relativi superiori alle femmine per ogni fascia d'età.




Figura 1.2: Distribuzione del tasso di donatori tra i residenti per anno, età e genere

Nel 2002, Cartocci riportava un tasso di donatori pari a 384 per 10.000 residenti; successivamente, i dati sintetizzati da Paola Bordandini (vedi Bordandini (2025)) indicano un incremento a 438 nel 2009 e a 454 nel 2022. Sulle nostre elaborazioni per Trieste - calcolate come rapporto tra donatori unici annui e residenti ISTAT nello stesso anno (per età e genere, poi aggregati) - il tasso complessivo risulta pari a 230 per 10.000 nel 2009, raggiunge un minimo di 216 nel 2021 e risale a 223 nel 2023, segnalando un lieve impatto congiunturale della pandemia e successivamente

recuperato.

Se il tasso è stabile, purtroppo non si può dire lo stesso per il numero assolto di donazioni, in quanto il numero di potenziali donatori continua a diminuire e il numero di coloro che ne hanno bisogno è in continuo aumento. Scopo di questa tesi è, perciò, costruire uno strumento usufruibile dal personale medico per prevenire l'abbandono del ciclo donativo da parte dei donatori ed incrementare, ove possibile, il numero di donazioni annue da parte del donatore.

2 Modelli Lineari Generalizzati

Questo capitolo analizzerà i modelli lineari generalizzati, potenti strumenti comunemente diffusi in tutti gli ambiti pratici. Sono tra i più usati grazie alla loro semplicità di costruzione e la loro facilità d'interpretazione. Tuttavia, nel capitolo successivo, mostreremo delle integrazioni per una maggiore flessibilità e dinamismo del modello stesso.

2.1 Teoria dei GLM

I modelli lineari generalizzati, abbreviati GLM, sono un'estensione dei modelli di regressione lineare. Per comprendere appieno il significato dei *Generalized Linear Model* si introducono prima i modelli di regressione lineare, i metodi di stima dei coefficienti e gli elementi che li caratterizzano. Successivamente si passerà alla loro estensione e all'utilizzo della famiglia esponenziale, citando alcune distribuzioni che saranno poi impiegate nei modelli.

2.1.1 Regressione Lineare

Un modello statistico è una rappresentazione matematica, e quindi semplificata, del processo che genera i dati. La semplificazione passa attraverso assunzioni probabilistiche che rendono esplicito cosa vogliamo descrivere (per esempio la media, la varianza o l'intera distribuzione di una variabile) e in che modo i dati possano essere considerati plausibili sotto tali assunzioni. Nel caso della regressione lineare, l'obiettivo è comprendere e quantificare la relazione tra una variabile dipendente Y e una o più variabili esplicative X , concentrandosi in particolare su come varia il valore medio di Y al variare di X .

Nota

A causa della molteplicità di applicazioni in ambiti diversi, non esiste una terminologia univoca. Nel testo Y sarà anche chiamata variabile dipendente, outcome, output o target; X potrà essere detta variabile indipendente, covariata, feature, predittore o input.

Quando vogliamo modellare la dipendenza media di Y da X , introduciamo la funzione di regressione, definita come $m(x) = \mathbb{E}[Y \mid X = x]$. Questa funzione “riassume” il comportamento medio della risposta dato il valore delle covariate. Il modello di

regressione lineare assume che tale dipendenza media sia lineare nei parametri: nella regressione lineare semplice (una sola covariata scalare X) si postula che

$$\mathbb{E}[Y \mid X] = \alpha + \beta X, \quad (2.1)$$

dove α è l'intercetta, il valore atteso di Y quando $X = 0$, e β è il coefficiente di regressione, ovvero quanto ci si attende che Y cambi in media per un incremento unitario di X . Questa espressione descrive la componente deterministica o sistematica del modello: specifica come si muove la media condizionata di Y quando X varia. È importante notare che “linearità” qui significa linearità nei parametri: possiamo includere trasformazioni di X (ad esempio X^2 , $\log X$, ...) e restare dentro il perimetro della regressione lineare, purché i rispettivi coefficienti compaiano linearmente.

Per collegare la media condizionata alla variabilità dei dati reali, aggiungiamo una componente aleatoria. Il modello stocastico corrispondente scrive la variabile osservata come

$$Y = \alpha + \beta X + \varepsilon, \quad (2.2)$$

dove ε è un errore casuale che raccoglie tutto ciò che non è esplicitamente modellato dalla parte sistematica: fattori non osservati, errori di misura, variabilità intrinseca. La principale assunzione è che l'errore non introduca distorsioni nella media condizionata, cioè che $\mathbb{E}[\varepsilon \mid X] = 0$; in tal modo la relazione Equazione 2.1 rimane valida. Spesso, per rendere l'inferenza più semplice e precisa, si aggiunge che la varianza degli errori (condizionata a X) sia costante, $\text{Var}(\varepsilon \mid X) = \sigma^2$ (omoschedasticità), e che gli errori siano incorrelati tra osservazioni distinte. Quando si dispone di un campione $i = 1, \dots, n$, queste ipotesi si traducono in $\mathbb{E}[\varepsilon_i \mid X_i] = 0$, $\text{Var}(\varepsilon_i \mid X_i) = \sigma^2$ e $\text{Cov}(\varepsilon_i, \varepsilon_j \mid X) = 0$ per $i \neq j$. Un'ulteriore ipotesi, più restrittiva, è che gli errori siano gaussiani: $\varepsilon \mid X \sim \mathcal{N}(0, \sigma^2)$. Questa normalità non è indispensabile per stimare correttamente la media, ma consente risultati esatti in piccoli campioni; in alternativa, si ricorre ad argomentazioni asintotiche o a correzioni robuste della varianza quando l'omoschedasticità o l'indipendenza non sono credibili.

La regressione lineare si estende anche al caso multivariato, in cui Y dipende da più predittori. Indicando con $x = (1, x_1, \dots, x_p)^\top$ il vettore delle covariate che include un 1 iniziale per l'intercetta e con $\beta = (\alpha, \beta_1, \dots, \beta_p)^\top$ il vettore dei parametri, la componente sistematica diventa $\mathbb{E}[Y \mid X = x] = x^\top \beta$. L'interpretazione dei coefficienti rimane invariata: β_j misura la variazione media di Y associata a un incremento unitario di X_j , a parità delle altre covariate. L'intercetta α , invece, rappresenta la media attesa quando tutte le covariate sono poste a zero, interpretazione utile solo se quello zero ha significato nel contesto applicativo.

i Nota

È comodo inglobare l'intercetta nella matrice delle covariate aggiungendo una

colonna di 1, e scrivere il modello come

$$Y = X\beta + \varepsilon, \quad \mathbb{E}[\varepsilon | X] = 0, \quad \text{Var}(\varepsilon | X) = \sigma^2 I.$$

Qui Y è un vettore $n \times 1$ degli esiti osservati, X è una matrice $n \times (p+1)$ di covariate (con la prima colonna di 1), β è il vettore dei parametri e ε è il vettore degli errori. La condizione di rango pieno di X garantisce l'identificabilità dei coefficienti (assenza di multicollinearità perfetta).

Le ipotesi appena discusse svolgono ruoli distinti. La media nulla condizionata $\mathbb{E}[\varepsilon | X] = 0$ è la chiave per interpretare la parte deterministica come media condizionata e per ottenere stime non distorte dei coefficienti con metodi come i minimi quadrati. Le ipotesi su varianza costante e indipendenza fra errori, invece, sono cruciali per la validità delle misure di incertezza standard (errori standard, intervalli di confidenza, test) e per l'efficienza degli stimatori classici; quando falliscono (eteroschedasticità, autocorrelazione), si possono ancora stimare correttamente gli effetti medi ma occorre adeguare l'inferenza, ad esempio con errori standard robusti o modelli che esplicitino la struttura di dipendenza. Infine, l'eventuale normalità degli errori fornisce una comoda idealizzazione: non è la sostanza del modello di regressione lineare, bensì un'ipotesi aggiuntiva che semplifica i calcoli, soprattutto in piccoli campioni.

Quindi, la regressione lineare scompone il fenomeno in una parte deterministica, $x^\top \beta$, che determina la variazione media in base ai predittori, e in una parte aleatoria, ε , che cattura la variabilità non spiegata.

2.1.2 Metodi di stima

Nel modello lineare classico $Y = X\beta + \varepsilon$ sotto le ipotesi che $\mathbb{E}[\varepsilon] = 0$ e $\text{Var}(\varepsilon) = \sigma^2 I$, allora si può usare lo stimatore ai minimi quadrati ordinari (OLS) che minimizza la somma dei quadrati dei residui:

$$\hat{\beta}_{\text{OLS}} = \arg \min_{\beta} (Y - X\beta)^\top (Y - X\beta) = (X^\top X)^{-1} X^\top Y. \quad (2.3)$$

Se si assume in più $\varepsilon \sim \mathcal{N}(0, \sigma^2 I)$, allora $\hat{\beta}_{\text{OLS}}$ coincide con lo stimatore di massima verosimiglianza (MLE). La funzione di verosimiglianza è

$$L(\beta, \sigma^2; Y) \propto (\sigma^2)^{-n/2} \exp\left(-\frac{1}{2\sigma^2} (Y - X\beta)^\top (Y - X\beta)\right), \quad (2.4)$$

e massimizzarla rispetto a β equivale a minimizzare la somma dei quadrati.

Curiosità

Nei GLM la stima avviene per massima verosimiglianza nella famiglia esponenziale. Indicando con $\mu = \mathbb{E}[Y | X]$ e con $g(\mu) = \eta = X\beta$ la funzione

di collegamento, le equazioni di score portano all'algoritmo IRLS (Iteratively Reweighted Least Squares): a ogni iterazione si risolve un problema di minimi quadrati pesati

$$\beta^{(t+1)} = \arg \min_{\beta} \|W^{1/2} (z - X\beta)\|^2,$$

dove W è una matrice di pesi dipendente da $\mu^{(t)}$ e z è la “variabile dipendente lavorata” (working response). La convergenza fornisce $\hat{\beta}_{\text{MLE}}$.

2.1.3 Estensione della Regressione Lineare

Il GLM si compone di tre elementi:

- componente aleatoria: $Y_i | X_i \sim \text{famiglia esponenziale}(\mu_i, \phi)$;
- componente sistematica: $\eta_i = x_i^\top \beta$;
- funzione di collegamento: $g(\mu_i) = \eta_i$.

Il collegamento canonico rende lineare il parametro naturale (es. logit per Binomiale, log per Poisson, inversa per Gamma). Ogni famiglia è caratterizzata da una funzione di varianza $V(\mu)$ che determina la struttura di dispersione: $\text{Var}(Y_i | X_i) = \phi V(\mu_i)$.

La qualità di adattamento si valuta tramite devianza, AIC/BIC e diagnostiche dei residui. La scelta di famiglia e link è guidata dalla natura della risposta (discreta/continua, supporto, presenza di zeri) e dall'interpretabilità dei coefficienti.

La funzione di regressione lineare è lineare rispetto ai parametri β , anche se la relazione tra X e Y non deve necessariamente essere lineare. La differenza tra gli LM e i GLM è proprio la funzione di collegamento, che nei modelli lineari non sarebbe altro che la funzione identità, ovvero $g(\mu_i) = \mu_i$.

2.1.4 Famiglia Esponenziale

Nei modelli lineari generalizzati (GLM), la variabile dipendente Y è modellata seguendo una distribuzione appartenente alla famiglia esponenziale. Una distribuzione è parte della famiglia esponenziale se la sua funzione di densità di probabilità (o funzione di massa di probabilità, nel caso discreto) può essere espressa nella forma:

$$f_Y(y|\theta, \phi) = \exp \left(\frac{y\theta - b(\theta)}{\phi} + c(y, \phi) \right)$$

{eq-exp_family}

dove:

- θ è il parametro naturale della distribuzione,
- ϕ è il parametro di dispersione,

- $b(\theta)$ è una funzione che determina la forma della distribuzione,
- $c(y, \phi)$ è una funzione che non dipende da θ .

Questa forma generale include molte distribuzioni comuni, come:

1. Distribuzione Normale:

- $Y \sim \mathcal{N}(\mu, \sigma^2)$
- Forma esponenziale: $\theta = \mu$, $\phi = \sigma^2$, $b(\theta) = \frac{\theta^2}{2}$, $c(y, \phi) = -\frac{y^2}{2\phi} - \frac{1}{2} \log(2\pi\phi)$.

2. Distribuzione Binomiale:

- $Y \sim \text{Binomiale}(n, p)$
- Forma esponenziale: $\theta = \log\left(\frac{p}{1-p}\right)$, $\phi = 1$, $b(\theta) = n \log(1 + e^\theta)$, $c(y, \phi) = \log\left(\binom{n}{y}\right)$.

3. Distribuzione Poisson:

- $Y \sim \text{Poisson}(\lambda)$
- Forma esponenziale: $\theta = \log(\lambda)$, $\phi = 1$, $b(\theta) = e^\theta$, $c(y, \phi) = -\log(y!)$.

Queste distribuzioni permettono di modellare variabili dipendenti Y che non sono normalmente distribuite, ampliando le applicazioni dei GLM rispetto ai modelli di regressione lineare tradizionali. La scelta della distribuzione appropriata dipende dalla natura dei dati e dal tipo di variabile dipendente che si sta modellando.

Nei modelli lineari generalizzati (GLM), la funzione di collegamento (*link function*) $g(\cdot)$ stabilisce una relazione tra il valore atteso della variabile dipendente Y , denotato come $E[Y|X]$, e una combinazione lineare delle variabili indipendenti. Questa relazione è espressa come:

$$g(E[Y|X]) = \eta = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p$$

dove η è il predittore lineare, β_0 è l'intercetta, e $\beta_1, \beta_2, \dots, \beta_p$ sono i coefficienti di regressione associati alle variabili indipendenti $X_1, X_2, \dots, X_p$.

La funzione di collegamento $g(\cdot)$ permette di modellare relazioni non lineari tra X e Y , trasformando il valore atteso di Y in modo che possa essere espresso come una combinazione lineare delle variabili indipendenti. Ad esempio, nel caso di una regressione logistica, la funzione di collegamento è il logit, definito come:

$$g(E[Y|X]) = \log\left(\frac{E[Y|X]}{1 - E[Y|X]}\right)$$

{eq-link_function}

Questa trasformazione consente di modellare la probabilità che Y assuma un certo valore in funzione delle variabili indipendenti, pur mantenendo la linearità nei parametri. (James et al. 2013)

2.2 Modelli GLM

L'analisi esplicativa utilizza, per ciascun donatore, il conteggio totale di donazioni accumulate nel periodo 2009–2023 come variabile risposta discreta $Y_i = \text{total_donations}_i$. Le covariate includono la classe d'età (all'ultimo anno osservato), anno della prima donazione e genere. Per limitare l'influenza di outlier rari si esclude la coda estrema ($Y_i < 100$) e si considerano solo i donatori *attritional*, coerentemente con i vincoli clinici annui e con la cadenza osservativa.

2.2.1 Quasi-Poisson

Teoria del quasi-Poisson

La teoria del quasi-Poisson è un'estensione del modello di regressione di Poisson utilizzata nei modelli lineari generalizzati (GLM) per gestire dati di conteggio che mostrano overdispersione. L'overdispersione si verifica quando la varianza dei dati è maggiore della media, una situazione che il modello di Poisson standard non può gestire poiché assume che la varianza sia uguale alla media.

Nel modello di Poisson standard, la distribuzione di Y è definita come:

$$Y \sim \text{Poisson}(\lambda)$$

dove λ è il parametro di intensità, e la varianza è uguale alla media: $\text{Var}(Y) = E[Y] = \lambda$.

Nel modello quasi-Poisson, invece, la varianza è proporzionale alla media, ma con un fattore di dispersione ϕ :

$$\text{Var}(Y) = \phi \cdot \lambda$$

dove ϕ è il parametro di dispersione che permette di modellare l'overdispersione. Quando $\phi > 1$, indica che c'è overdispersione nei dati.

La funzione di collegamento nel modello quasi-Poisson è la stessa del modello di Poisson, tipicamente il logaritmo naturale:

$$g(E[Y|X]) = \log(\lambda) = \eta = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p$$

Il modello quasi-Poisson utilizza la stessa struttura lineare per il predittore η , ma permette una varianza maggiore rispetto alla media, fornendo una maggiore flessibilità nel modellare dati di conteggio che non seguono strettamente la distribuzione di Poisson.

Tabella 2.1: Coefficienti del modelli di Quasi-Poisson

Characteristic	log(IRR)	95% CI	p-value
genderM	0.53	0.50, 0.55	<0.001
class_age(25,35]	0.56	0.51, 0.60	<0.001
class_age(35,45]	0.90	0.85, 0.94	<0.001
class_age(45,55]	1.3	1.2, 1.3	<0.001
class_age(55,65]	1.5	1.4, 1.5	<0.001
class_age(65,70]	1.6	1.6, 1.7	<0.001

Abbreviations: CI = Confidence Interval, IRR = Incidence Rate Ratio

Risultati

Nel nostro dataset la dispersione stimata risulta essere 5,7 nettamente maggiore di 1, evidenziando overdispersione marcata rispetto al Poisson puro.




Figura 2.1: Risultati del modello Quasi-Poisson

2.2.2 Tweedie

Teoria della Tweedie

Il modello Tweedie è un tipo di modello lineare generalizzato (GLM) che gestisce dati che possono avere una distribuzione di probabilità con una combinazione di caratteristiche di distribuzioni di Poisson e gamma. È particolarmente utile per modellare dati che includono valori zero e continui positivi, come i dati di assicurazione che comprendono sinistri con importi variabili.

Caratteristiche del Modello Tweedie

Il modello Tweedie appartiene alla famiglia esponenziale e si caratterizza per avere una funzione di varianza della forma:

$$Var(Y) = \phi \cdot \mu^p$$

dove:

- $\mu = E[Y]$ è il valore atteso,
- ϕ è il parametro di dispersione,
- p è il parametro di potenza che determina la forma della distribuzione.

Differenze rispetto al Quasi-Poisson

Il modello quasi-Poisson, come discusso in precedenza, assume che la varianza sia proporzionale alla media ($Var(Y) = \phi \cdot \lambda$), il che è utile per gestire l'overdispersione nei dati di conteggio.

Il modello Tweedie, invece, generalizza ulteriormente questa relazione introducendo il parametro di potenza p , che permette di modellare una gamma più ampia di distribuzioni:

- $p = 1$: corrisponde al modello di Poisson, dove la varianza è uguale alla media.
- $p = 2$: corrisponde al modello gamma, utilizzato per dati continui positivi.
- $1 < p < 2$: rappresenta una distribuzione Tweedie, che combina caratteristiche di Poisson e gamma, utile per dati con valori zero e continui positivi. Verrà utilizzata successivamente.
- $p = 3$: corrisponde al modello gaussiana inversa.

Funzione di Collegamento

Come nei modelli GLM, il modello Tweedie utilizza una funzione di collegamento per stabilire la relazione tra il valore atteso e una combinazione lineare delle variabili indipendenti:

$$g(E[Y|X]) = \eta = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p$$

La scelta della funzione di collegamento dipende dalla natura dei dati e dal valore del parametro di potenza p .

Tuning del parametro p

La variabile di risposta utilizzata per il tuning, `total_donations`, è strettamente positiva nel dataset di training (nessun valore zero: anche se la moda è 1). In questo setting non si osserva la classica “massa a zero” dei dati di frequenza annuale, bensì una conta cumulata positiva per donatore.

Il profilo di verosimiglianza spinge verso $p \simeq 3$, infatti la profilazione di $\log L$ in funzione di p risulta crescente fino al bordo superiore della griglia ($p = 3$). Questo comportamento è coerente con:

- assenza di zeri (quindi nessuna necessità della componente “Poisson” per modellare la massa a zero);
- relazione varianza–media che cresce più che quadraticamente al crescere di μ ;
- coda destra relativamente pesante: la IG ($p = 3$) ammette varianze che aumentano molto rapidamente con il livello medio, spesso risultando preferita alla Gamma quando pochi soggetti hanno conteggi molto alti.




Figura 2.2: Risultati del *grid searching* per p

Risultati

Il tuning del parametro di potenza suggerisce $p = 3$, giustificando il modello della gaussiana inversa. Il modello tweedie non è dunque da considerare ma è meglio piuttosto usare direttamente un modello gaussiana inversa, o gamma. Anche se, come vedremo sono modelli per valutare variabili nel continuo.

2.2.3 Poisson troncata a zero

Teoria della Poisson troncata

La Poisson troncata a zero è la distribuzione di Poisson condizionata all'evento $Y > 0$. È adatta quando la variabile di risposta è un conteggio strettamente positivo (nessuno zero osservato). La funzione di massa di probabilità è:

$$\Pr(Y = y \mid Y > 0, \mu) = \frac{e^{-\mu} \mu^y / y!}{1 - e^{-\mu}}, \quad y = 1, 2, \dots \quad (2.5)$$

dove $\mu > 0$ è l'intensità Poisson “non troncata”.

La media e la varianza condizionate sono:

$$\mathbb{E}[Y \mid Y > 0] = \frac{\mu}{1 - e^{-\mu}},$$

$$\text{Var}(Y \mid Y > 0) = \mathbb{E}[Y \mid Y > 0] \left(1 + \mu - \mathbb{E}[Y \mid Y > 0] \right).$$

Per μ grande, $e^{-\mu} \approx 0$ e si recupera il caso Poisson standard; per μ piccola, il troncamento “spinge” la media sopra 1 e riduce la varianza relativa.

La verosimiglianza include un termine di normalizzazione $(1 - e^{-\mu})$ che dipende da μ ; ciò rende il modello “GLM-like” ma non un GLM canonico in senso stretto. È appropriato quando gli zeri sono strutturalmente assenti o esclusi per costruzione del campione, quindi esattamente per il nostro caso dove abbiamo a disposizione solo le osservazioni di chi ha donato.

Funzione di collegamento

In pratica si specifica un predittore lineare per il parametro di intensità “di base” μ tramite link log:

$$\log \mu = \eta = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p.$$

Si noti che il valore atteso del modello è $\mathbb{E}[Y \mid X] = \mu / (1 - e^{-\mu}) \neq \mu$, dunque il link agisce su μ , non direttamente sulla media condizionata. L'inferenza avviene per massima verosimiglianza (p.es. via glmmTMB).




Figura 2.3: Coefficienti del modello di Poisson troncato in zero

Risultati

2.2.4 Binomiale Negativa

Teoria della Binomiale Negativa

La Binomiale Negativa (NB) è una famiglia discreta per conteggi con overdispersione rispetto alla Poisson. Una parametrizzazione comune per i GLM è in termini di media μ e parametro di dispersione $\theta > 0$:

$$\mathbb{E}[Y] = \mu, \quad \text{Var}(Y) = \mu + \frac{\mu^2}{\theta}.$$

Equivalentemente, in parametrizzazione (r, p) con $r = \theta$ e $p = \frac{\theta}{\theta + \mu}$, la distribuzione è la seguente:

$$\Pr(Y = y) = \binom{y + r - 1}{y} (1 - p)^y p^r, \quad y = 0, 1, 2, \dots \quad (2.6)$$

dove $r > 0$ e $0 < p < 1$.

La BN ha supporto discreto $y \in \{0, 1, 2, \dots\}$ e gestisce naturalmente overdispersione (varianza $>$ media). Rispetto alla Poisson, NB aggiunge un termine quadratico in μ nella varianza, controllato da θ (più grande è θ , minore è l'overdispersione, $\theta \rightarrow \infty$ tende a una Poisson). Nei GLM NB è prassi l'uso del link log sulla media.




Figura 2.4: Residui del modello negativo binomiale

Risultati

2.2.5 Performance

I modelli sono stati addestrati sulla stessa parte deterministica (stessa formula per il predittore lineare, quindi stessi regressori e medesimo link log), variando unicamente la componente aleatoria e l'errore di stima indotto dalla distribuzione (Poisson, Quasi-Poisson, Tweedie, Gamma, Binomiale Negativa, Poisson troncata). Ciò rende il confronto “a parità di sistema”, attribuendo le differenze prestazionali alla sola specifica stocastica.

Le metriche considerate sul test set sono:

- errore quadratico medio (RMSE) che penalizza maggiormente gli errori grandi (squadra gli scarti), perciò è sensibile agli outlier

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2},$$

- errore assoluto medio (MAE) che misura l'errore medio “in unità della risposta” ed è più robusto a code pesanti

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|,$$

Tabella 2.2: Performance dei modelli

```
# A tibble: 6 x 4
```

	model	rmse	mae	rsq
	<chr>	<dbl>	<dbl>	<dbl>
1	Gamma	6.73	4.47	0.233
2	Negative Binomial	6.73	4.47	0.232
3	Poisson	6.73	4.48	0.233
4	Quasi-Poisson	6.73	4.48	0.233
5	Truncated Poisson	6.72	4.47	0.234
6	Tweedie	6.75	4.44	0.229

- coefficiente di determinazione (R^2) che quantifica la quota di variabilità spiegata dalle previsioni (qui intesa in senso predittivo fuori campione, *test set*)

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}, \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i.$$

Sui dati di test le prestazioni sono molto vicine tra i modelli; tuttavia la Poisson troncata ottiene il miglior RMSE e il miglior R^2 (Tabella 2.2), risultando leggermente superiore a Gamma, Poisson, Quasi-Poisson e Binomiale Negativa; il Tweedie registra il MAE più basso ma peggiora su RMSE e R^2 .

Nel complesso, l'evidenza congiunta di RMSE e R^2 indica la Poisson troncata come scelta migliore, coerente anche con il supporto dei dati, conteggi strettamente positivi. Le differenze sono piccole ma sistematiche, e riflettono come la specifica della distribuzione — a parità di parte sistematica — influisca sulla calibrazione delle previsioni e sulla gestione dell'eteroschedasticità.

2.3 Modello Temporale

Il modello temporale adottato è un quasi-Poisson con link log, in cui il conteggio delle donazioni nel 2019 è spiegato dai conteggi nei tre anni precedenti, dal genere e dalle coorti generazionali. L'interpretazione dei coefficienti è quella tipica dei GLM con link log: esponenziando le stime si ottengono gli incidence rate ratios (IRR), cioè moltiplicatori del tasso atteso a parità delle altre variabili. I risultati delineano una dinamica con forte persistenza di breve periodo: ogni donazione aggiuntiva nel 2018 moltiplica l'atteso del 2019 di circa 1.32, l'effetto del 2017 scende a circa 1.15 e quello del 2016 a 1.08 (Figura 2.5b). La graduale attenuazione del contributo man mano che ci si allontana nel tempo è coerente con l'idea di una “memoria” che si consuma: quanto più recente è l'abitudine alla donazione, tanto più incide sull'attività dell'anno successivo.

Tabella 2.3: Coefficienti del modello temporale

Characteristic	log(IRR)	95% CI	p-value
y_2018	0.32	0.30, 0.35	<0.001
y_2017	0.15	0.12, 0.17	<0.001
y_2016	0.08	0.06, 0.10	<0.001
gender			
F	—	—	
M	0.23	0.18, 0.29	<0.001
class_year			
(1950,1960]	—	—	
(1960,1970]	0.06	-0.03, 0.15	0.2
(1970,1980]	0.04	-0.05, 0.13	0.4
(1980,1990]	-0.06	-0.15, 0.04	0.3
(1990,2000]	-0.22	-0.32, -0.12	<0.001
(2000,2010]	-2.1	-2.5, -1.8	<0.001

Abbreviations: CI = Confidence Interval, IRR = Incidence Rate Ratio

A parità di storia donazionale recente, i maschi presentano livelli attesi più alti, con un IRR intorno a 1.23, quindi un incremento di circa il 23% (Figura 2.5a). Le coorti mostrano differenze contenute nelle classi intermedie, mentre emergono penalizzazioni significative nelle coorti più giovani: per i nati tra il 1990 e il 2000 il tasso atteso è circa il 20% più basso, e per i nati tra il 2000 e il 2010 la riduzione è molto marcata. Quest'ultimo risultato è plausibile alla luce di una minore anzianità donazionale e di vincoli anagrafici che limitano l'intensità donativa nelle fasce più giovani.

Sul piano statistico, la dispersione stimata è leggermente inferiore a 1 ($\phi \approx 0.956$), segnalando una lieve underdispersione rispetto alla Poisson ideale; la scelta quasi-Poisson rimane appropriata perché fornisce errori standard robusti senza imporre $Var(Y) = E(Y)$. La devianza residua è pari a 8441, contro una devianza nulla di 12921: si tratta di una riduzione di circa il 35%, un livello di adattamento non banale per un modello intenzionalmente parsimonioso, in cui la struttura laggata cattura la quota principale della variabilità interannuale. Poiché i predittori temporali sono inevitabilmente correlati tra loro, è opportuno verificare la multicollinearità (ad esempio con indici VIF) e, se necessario, considerare specifiche più compatte — una media mobile pesata o una struttura a lag distribuiti con penalizzazione. Infine, il target è il 2019, quindi in un contesto pre-pandemico: per estensioni successive conviene introdurre indicatori di shock (COVID) come verrà visto nel capitolo successivo.




Figura 2.5: Effetti del modello predittivo con ritardi integrati

3 Bayesian Hidden Markov Models

3.1 Accenni di Teoria

3.1.1 Processo Markoviano

Un processo stocastico è una collezione di variabili aleatorie indicizzate da un parametro, tipicamente il tempo, che può essere continuo o discreto ma con la condizione che sia equidistante. La sequenza si denota come $\{X_t\}_{t \geq 1}$. Le variabili aleatorie possono essere continue o discrete e possono essere correlate tra loro. Questa dipendenza caratterizza alcune delle proprietà che il processo può assumere come la stazionarietà, l'indipendenza o la correlazione. Queste proprietà possono definire categorie di processi stocastici, ad esempio i processi di Poisson sono caratterizzati da eventi che si verificano in modo indipendente e i processi stazionari sono caratterizzati da proprietà statiche, che non cambiano nel tempo.

Un processo stocastico è una collezione di variabili aleatorie indicizzate da un parametro (tipicamente il tempo). Nel caso discreto a passi equispaziati, la sequenza si denota come $\{X_t\}_{t \geq 1}$. Un processo è markoviano di ordine 1 se il futuro dipende dal presente ma non dal passato più remoto.



Il processo markoviano è un caso specifico dei processi stocastici, e in questo caso la proprietà principale è che lo stato futuro dipende solamente dal suo presente e non dal passato. L'ipotesi assuntiva è molto forte e permette di semplificare drasticamente un modello di serie storiche. Infatti non servirà più osservare l'intero passato per predire il futuro, ma basterà appena avere le informazioni sullo stato precedente. Ciò si basa su proprietà base della probabilità, nel caso di un processo markoviano di primo ordine, l'osservazione successiva dipenderà solamente dalla precedente:

Definizione 3.1 (Proprietà di Markov). Sia $\{X_t\}$ un processo stocastico. Allora $\{X_t\}$ è markoviano di ordine 1 se e solo se

$$\Pr(X_t \mid X_{t-1}, \dots, X_1) = \Pr(X_t \mid X_{t-1}) \quad t \geq 2.$$

Per la Definizione 3.1, tutte le future osservazioni sono indipendenti da quelle passate, ad eccezione di k osservazioni più recenti, dove k è il grado della catena markoviana: $x_{n+1} \perp x_{n-1} \mid x_n$.

Una catena di Markov omogenea (stazionaria nel tempo) è caratterizzata da:

- la matrice di transizione $\mathbf{A}$ con elementi $a_{ij} = \Pr(X_t = j \mid X_{t-1} = i)$, per $t \geq 2$;
- il vettore di probabilità iniziali $\boldsymbol{\pi}$ con $\pi_i = \Pr(X_1 = i)$;
- lo spazio degli stati finiti $Z = \{1, \dots, K\}$.

Proprietà strutturali

Di seguito alcune proprietà importanti che verranno usate in seguito per la descrizione e definizione degli Hidden Markov Model in generale e di quello specificatamente utilizzato nel progetto.

Definizione 3.2 (Ergodicità (catene omogenee)). Sia $\{X_t\}_{t \geq 0}$ una catena di Markov a tempo discreto su spazio degli stati finito Z con matrice di transizione $\mathbf{A}$ (costante nel tempo). Se la catena è irriducibile, aperiodica e positivamente ricorrente, allora esiste ed è unica una distribuzione stazionaria $\boldsymbol{\pi}^*$ tale che $\boldsymbol{\pi}^* \mathbf{A} = \boldsymbol{\pi}^*$. Levin, Peres, e Wilmer (2009).

Il tempo di mixing misura quanto rapidamente la distribuzione della catena “dimentica” le condizioni iniziali e si avvicina a $\boldsymbol{\pi}^*$.

Definizione 3.3 (Catena di Markov omogenea nel tempo). Una catena di Markov discreta $\{X_t\}_{t \geq 0}$ su spazio degli stati finito Z si dice omogenea (o stazionaria nel tempo) se esiste una matrice di transizione costante $\mathbf{A}$ tale che, per ogni $t \geq 1$ e per ogni $i, j \in Z$,

$$\Pr(X_t = j \mid X_{t-1} = i) = A_{ij},$$

ossia le probabilità di transizione non dipendono dal tempo. Una distribuzione $\boldsymbol{\pi}$ si dice stazionaria se soddisfa

$$\boldsymbol{\pi} \mathbf{A} = \boldsymbol{\pi}, \quad \boldsymbol{\pi} \mathbf{1} = 1, \quad \boldsymbol{\pi} \geq \mathbf{0}.$$

Una catena, invece, è detta non omogenea se la transizione al tempo t è data da una matrice $\mathbf{A}_t$ che può dipendere da t o da covariate x_t , cioè $\mathbf{A}_t = \mathbf{A}(x_t)$. In generale:

- non esiste una distribuzione stazionaria unica (indipendente dal tempo) che soddisfi $\boldsymbol{\pi} \mathbf{A}_t = \boldsymbol{\pi}$ per tutti i t ;
- si usa la nozione di “ergodicità debole”: le distribuzioni indotte da condizioni iniziali diverse si avvicinano tra loro sotto opportune condizioni di contrazione.

3.1.2 Hidden Markov Models (HMM)

Come citato nel capitolo precedente, le catene markoviano sono molto utili perché riescono a riassumere tutta la storia passata con appena k passi precedenti, dove k è l'ordine della catena markoviana. Quest'ipotesi permette di ridurre la fattorizzazione passando da

$$Pr(x_1, \dots, X_N) = Pr(x_1)Pr(x_2|X_1)Pr(x_3|x_2, X_1) \dots Pr(x_n + 1|x_n, \dots, x_{n-k+1}) \dots$$

In questo modo il modello è computazionalmente efficiente in quanto ha bisogno di processare molta meno informazione.

Tuttavia, ciò non permette di modellare strutture più complesse, e in questo caso bisogna aggirare la proprietà di Markov (Definizione 3.1). Si introducono quindi delle variabili latenti, delle variabili nascoste (*hidden*), che non sono osservate. Vengono costituiti due stage/serie dipendenti tra loro. La prima serie è costituita da una catena markoviana di variabili latenti, Z_t al tempo t , che non possiamo osservare e che dipendono solo dallo stato precedente, Z_{t-1} allo stato $t - 1$. La seconda serie, invece, sono le variabili osservate, e la loro emissione (distribuzione) dipende dallo stato latente.

Con parametri $\theta = (\boldsymbol{\pi}, \mathbf{A}, \boldsymbol{\phi})$ la fattorizzazione congiunta è:

$$Pr(\mathbf{y}, \mathbf{z} \mid \theta) = Pr(z_1 \mid \boldsymbol{\pi}) \prod_{t=2}^T Pr(z_t \mid z_{t-1}, \mathbf{A}) \prod_{t=1}^T Pr(y_t \mid z_t, \boldsymbol{\phi}).$$

In aggiunta gli HMM permettono di modellare non solo una sequenza ma anche molteplici.

Estensioni degli HMM

Gli Hidden Markov Model possono essere estesi a problemi più generalizzati. Si possono quindi rompere o adattare alcune parti della sua struttura, come la matrice di transizione e le probabilità di emissione. Facendo ciò si aumenta il grado di complessità del modello perdendo leggermente la sua facile intuitività. Ma allo stesso tempo si vanno a migliorare notevolmente le sue prestazioni e la sua adattabilità al mondo reale. Di seguito vengono riportate alcune delle estensioni che verranno poi implementato nel modello predittivo.

Emissioni flessibili

Secondo Fan (2015), dato un HMM del primo ordine e che sia almeno ergodico (Definizione 3.2), allora si può definire una famiglia esponenziale per la distribuzione condizionata alle osservazioni, ovvero la distribuzione delle emissioni. Normalmente le emissioni sono dei parametri della distribuzione di Poisson, λ , e della distribuzione Gaussiana, μ o σ . In questo caso si andrebbe ad estendere il problema e si ipotizza una

famiglia esponenziale (vedi Sezione 2.1.4), che racchiude sia la distribuzione Poisson che la Gaussiana. I parametri della famiglia esponenziale, o della distribuzione scelta, non dipenderebbero unicamente dallo stato latente, ma, dipenderebbero da dei coefficienti β_k e da delle covariate W_t . Le covariate sono note, e possono cambiare nel tempo, permettendo al modello una flessibilità temporale garantendo la stazionarietà, nel caso in non venisse implementato un sistema di covariate come si vedrà nella sezione successiva. I parametri da stimare diventano, quindi, i β_k , e il loro valore sarà condizionato allo stato latente. Di conseguenza, si produrranno K GLM dove K è il numero di stati latenti.

Non omogeneità

Per aumentare le performance del modello o per studiare a fondo le dinamiche che possono influire nel cambio di stato, allora può essere interessante aggiungere delle covariate nella matrice di transizione. Il processo è simile a quello descritto nella sezione precedente (vedi Sezione 3.1.2), tuttavia in questo caso non garantiremmo più la proprietà di omogeneità (vedi Definizione 3.3).

3.1.3 Bayesiana

In un HMM l'approccio bayesiano fornisce un linguaggio naturale per incorporare conoscenza a priori e per regolarizzare stime potenzialmente instabili, soprattutto quando gli stati latenti sono pochi, i dati sono rumorosi e le transizioni rare. L'idea è assegnare distribuzioni a priori ai parametri chiave (probabilità iniziali sugli stati e matrice di transizione) e poi combinarle con l'evidenza dei dati per ottenere le posteriori. Tra le scelte più convenienti c'è la famiglia Dirichlet, coniugata rispetto a vettori di probabilità: consente aggiornamenti semplici e interpretazioni immediate in termini di “pseudo-conteggi”.

Nel caso di stati finiti $Z = \{1, \dots, K\}$, si pone una a priori Dirichlet sul vettore delle probabilità iniziali e, riga per riga, sulle transizioni:

$$\boldsymbol{\pi} \sim \text{Dirichlet}(\boldsymbol{\alpha}_\pi), \quad \mathbf{A}_{k,\cdot} \sim \text{Dirichlet}(\boldsymbol{\alpha}_{A_k}) \quad (k = 1, \dots, K).$$

Qui $\boldsymbol{\alpha}_\pi$ e $\boldsymbol{\alpha}_{A_k}$ sono vettori di iperparametri positivi. La loro somma rappresenta la “forza” della prior: quanto più è grande, tanto più la prior influenzerà la posteriore rispetto ai dati. Una prior simmetrica (tutte le componenti uguali) è non informativa in senso debole; una prior asimmetrica, invece, incorpora credenze specifiche, ad esempio maggiore massa sullo stato “inattivo” per $\boldsymbol{\pi}$ o maggiore persistenza sulla diagonale per le righe di $\mathbf{A}$.

Dati uno o più percorsi latenti $z_{1:T}$ la coniugatezza della Dirichlet corrisponde agli aggiornamenti per somma di conteggi. Se indichiamo con c_i il numero di sequenze che iniziano nello stato i e con n_{kj} il numero di transizioni osservate $k \rightarrow j$, allora

$$\boldsymbol{\pi} \mid z_1 \sim \text{Dirichlet}(\boldsymbol{\alpha}_\pi + \mathbf{c}), \quad \mathbf{A}_{k,\cdot} \mid z_{1:T} \sim \text{Dirichlet}(\boldsymbol{\alpha}_{A_k} + \mathbf{n}_{k,\cdot}),$$

dove $\mathbf{c} = (c_1, \dots, c_K)$ e $\mathbf{n}_{k\cdot} = (n_{k1}, \dots, n_{kK})$. Ne discendono formule chiuse per media e predittiva: ad esempio la stima bayesiana (posterior mean) del termine A_{kj} è

$$\mathbb{E}[A_{kj} \mid \text{dati}] = \frac{\alpha_{A_{kj}} + n_{kj}}{\sum_{h=1}^K (\alpha_{A_{kh}} + n_{kh})},$$

e la probabilità di transizione “one-step-ahead” integra automaticamente lo smoothing dei rari passaggi fuori diagonale. Questa proprietà è particolarmente utile quando alcune transizioni sono poco o per nulla osservate: la Dirichlet evita stime nulle e stabilizza l’inferenza.

Intuizione sui parametri Dirichlet

Pensare a α come a pseudo-conteggi: una prior simmetrica con $\alpha = 1$ per ciascuna voce equivale a “una osservazione virtuale” per stato; aumentare la diagonale nelle righe di $\mathbf{A}$ equivale a credere che la catena tenda a permanere nello stesso stato; usare α_π asimmetrica (ad esempio più grande sulla componente dello stato 0) riflette l’aspettativa che molte sequenze inizino “a riposo”.

Un tema tipico negli HMM è il “label switching”: gli stati possono scambiarsi etichette senza cambiare la verosimiglianza. Una prior Dirichlet asimmetrica su π e/o “diagonale rinforzata” su $\mathbf{A}$ spezza la simmetria, facilitando la stabilità numerica e l’interpretazione dei profili latenti.

Scelte pratiche

In problemi con forte persistenza conviene una prior sulle righe di $\mathbf{A}$ con massa più alta sulla diagonale; quando si sa che lo stato iniziale è sbilanciato (molti “inattivi”), una prior su π coerente con questa conoscenza accelera la convergenza e riduce il label switching. Le concentrazioni totali moderatamente piccole mantengono la prior “debole” lasciando ai dati il grosso dell’inferenza.

Dal punto di vista computazionale, l’uso di priors Dirichlet si integra bene con schemi variazionali o EM: i sufficient statistics sono i conteggi attesi di occupazione e di transizione, ottenibili da forward–backward. In variational Bayes o SVI, questi compaiono come termini attesi nell’ELBO e consentono aggiornamenti stabili anche su dataset ampi, mantenendo l’interpretabilità delle stime come “conteggi osservati + pseudo-conteggi”.

3.1.4 Teoria dell’algoritmo di Viterbi (caso generale)

Nel caso classico di HMM con distribuzione iniziale π , matrice di transizione $\mathbf{A}$ ed emissioni $b_j(y_t) = \Pr(y_t \mid z_t=j)$, l’algoritmo di Viterbi cerca il percorso a *Maximum A Posteriori* (MAP) $z_{0:T}^* = \arg \max_{z_{0:T}} \Pr(z_{0:T} \mid y_{0:T})$. L’idea è trasformare questo problema globale in una sequenza di passi locali grazie alla programmazione dinamica:

invece di tenere traccia di tutti i cammini possibili, si propaga nel tempo, per ciascuno stato j , il valore della “miglior” probabilità cumulativa che termina in j .

Per stabilità numerica si lavora in log-spazio. Si definisce quindi $\delta_t(j)$ come il massimo, tra tutti i cammini che arrivano a t in j , della log-probabilità congiunta fino a t . L’inizializzazione è immediata:

$$\delta_0(j) = \log \pi_j + \log b_j(y_0),$$

che combina la probabilità di partire nello stato j con la verosimiglianza dell’osservazione iniziale. Il passo ricorsivo somma l’evidenza al tempo t alla migliore prosecuzione dal tempo precedente:

$$\delta_t(j) = \log b_j(y_t) + \max_k \{ \delta_{t-1}(k) + \log A_{kj} \}.$$

Per ricostruire il percorso, oltre ai valori δ_t si memorizzano i “backpointer” $\psi_t(j)$, cioè l’indice k che massimizza l’espressione tra graffe. Al termine, si sceglie $z_T^* = \arg \max_j \delta_T(j)$ e si risale a ritroso con $z_{t-1}^* = \psi_t(z_t^*)$ fino a $t = 1$. In altre parole, Viterbi calcola in avanti i punteggi ottimali e, alla fine, riassume all’indietro il cammino MAP.

Dal punto di vista computazionale, Viterbi è lineare nella lunghezza della sequenza e quadratico nel numero di stati, con complessità $\mathcal{O}(T K^2)$ e memoria $\mathcal{O}(T K)$ (per i backpointer). In implementazione conviene usare sistematicamente la forma log e la “log-sum-exp trick” quando servono normalizzazioni, così da evitare underflow e garantire stabilità.

I motivi per preferirlo sono pratici oltre che teorici: restituisce un percorso ottimale globale rispetto alla perdita 0–1 sulla sequenza intera ed è efficiente anche su serie lunghe. Inoltre, è stabile numericamente grazie al lavoro in log ed è soprattutto deterministico e facilmente interpretabile, qualità preziose per analisi più approfondite e successive personalizzazioni. Infine, si adatta senza sforzo a contesti non omogenei o con covariate, come nel nostro HMM-GLM, perché la dinamica ricorsiva resta invariata e cambia soltanto la parametricità di π , A ed emissioni.

3.2 Il modello applicato alle donazioni

3.2.1 Pyro

Dopo la parte teorica, in questo capitolo parleremo della applicazione della teoria ai dati sulle donazioni di sangue. Se nel precedentemente capitolo era stato utilizzato quasi totalmente il linguaggio di programmazione statistica R, e i pacchetti `tidyverse` e `tidymodels`, in questo capitolo i modelli verranno sviluppati attraverso il linguaggio di programmazione python e il pacchetto `Pyro`.

Pyro è un linguaggio universale di programmazione probabilistica scritto in Python e costruito con **PyTorch** nel *backend*. Ma a cosa serve? Secondo Bingham et al. (2018), Pyro permette di scrivere in modo facile e flessibile modelli probablistici, tra cui modelli di *deep learning* e bayesiani. I punti di forza di Pyro sono i seguenti:

- universale, in quanto può rappresentare qualsiasi distribuzione di probabilità computabile;
- scalabile, ideale per lavorare su grandi *data set*;
- minimale, è costituito da un piccolo ma potente *core*, e
- flexible, è facilmente automatizzabile, ma al contempo controllabile, quando necessario.

Ovviamente non è l'unico strumento utilizzabile per costruire i modelli mostrati successivamente. Una valida alternativa è **stan**, implementata in R attraverso i pacchetti come **rstan**.

3.2.2 Dati e covariate

I dati sono stati inizialmente elaborati in R, successivamente esportati in formato tabellare (CSV), ed infine importati in Python. L'obiettivo era quello di ottenere dei dati in formato tabulare dove ogni riga rappresentasse il donatore e con una colonna per ogni anno d'osservazione, contenente il numero di donazioni effettuate in quello specifico anno. Infine, altre colonne con le informazioni sul donatore, come l'anno di nascita, il genere e l'età. Successivamente, i dati sono stati modificati ulteriormente addattandoli all'ambiente di sviluppo in Python.

Abbiamo ottenuto così un un pannello longitudinale con $N = 9236$ donatori e le loro donazioni negli anni 2009-2023 ($T = 15$) e le covariate con le informazioni demografiche sul donatore. Per la modellizzazione dei dati si è diviso il dataset iniziale in 4 dataset più piccoli:

1. il primo contenente le colonne costituite dai conteggi annuali per donatore;
2. il secondo contenente le covariate necessarie per la determinazione delle probabilità iniziali;
3. il terzo costituito dalle covariate per la matrice di transizione,
4. e l'ultimo contenente le covariate per i modelli GLM.

Dataset sulle osservazioni delle donazioni

Il primo dataset sarà costituito da sole $y_t \in \{0, 1, 2, 3, 4\}$, dove t è il tempo. Il limite superiore del dominio dei dati è dovuto a una regola clinica: ovvero un donatore può al più donare 4 volte all'anno per sangue intero. Questo ha portato all'utilizzo di distribuzioni probabilistiche improprie, ovvero che non erano contemplate per la natura dei dati, ma che a causa della loro forma, si adattavano molto bene al caso nostro.

La distribuzione di probabilità più appropriata sarebbe stata infatti una distribuzione binomiale, o una categorica. Tuttavia la distribuzione di Poisson era quella che meglio si adattava i dati, anche se è stata troncata sulla coda destra a causa della regola clinica.

Questi dati non hanno avuto bisogno di attenzione, in quanto sono le osservazioni dei donatori e l'output del nostro modello.

Dataset con le covariate per le probabilità iniziali

Il secondo dataset sarà usato per calcolare $\pi = Pr(Z_{n,1} | X_{n,1}^\pi)$, ovvero la probabilità dell'individuo n di iniziare nello stato k , date le covariate $X_{n,1}^\pi$, dove $X_{n,1}^\pi$ è una matrice di dimensione N, P_π con p_π il numero di covariate utilizzate.

Le probabilità iniziali vengono calcolate solo per il primo stato. Devono, perciò, sfruttare delle informazioni disponibili al tempo 1. Le sue covariate saranno di conseguenza statiche.

La sua importanza è relativa, infatti grazie alla matrice di transizione, le unità si sposteranno tra gli stati e assumeranno lo stato che più gli si adatta allo specifico tempo t .

Dataset con le covariate per la matrice di transizione

Il modello che verrà sviluppato in questo capitolo è diverso da un classico *hidden markov model* e non possiede tutte le sue proprietà. In specifico non gode della proprietà di omogeneità, ovvero non è un modello stazionario (vedi Definizione 3.3). Non ci aspettiamo che un donatore appartenga sempre allo stato, ovvero che sia propenso sempre allo stesso modo di donare. Riteniamo che esso dipenda da fattori esterni che influenzino il suo comportamento. Questi fattori non sono fissi e cambiano nel tempo. Sarà dunque necessario includere delle covariate dinamiche, che cambiano nel tempo, come l'età del donatore. Otterremo dunque una matrice di 3 dimensioni N, P_A, T dove N è il numero di donatori, P_A il numero di variabili usate e T gli anni usati dal modello.

Le covariate utilizzate saranno l'età e gli anni del covid. Analizzando l'età, si osserva come il suo andamento non sia lineare. Al crescere dell'età non si può assertare né che il numero di donazioni sia in aumento, né che il numero di donazioni sia in

diminuzione. Infatti agli estremi, ovvero nelle fasce d'età più giovani e più anziane si osserveranno un numero di donazioni minore mentre nella fascia centrale, un numero di donazioni maggiore. Sia $\mathbf{X}$ e $\mathbf{Y}$ due vettori (o matrici) e sia $\mathbf{A}$ una matrice di trasformazione tale che

$$\mathbf{Y} = \mathbf{A} \mathbf{X} + \varepsilon.$$

Il nostro obiettivo è trovare

$$\arg \min_{\mathbf{A} \in \mathbb{R}^{q \times p}} \|\mathbf{Y} - \mathbf{A} \mathbf{X}\|^2.$$

Le opzioni possibili per gestire il suddetto problema sono molteplici, dalle più semplici alle più complesse.

Tra le principali strategie si possono citare:

- **aggiunta di potenze della variabile:** ad esempio includendo termini quadratici o cubici dell'età ($\text{età}^2, \text{età}^3, \dots$) per catturare eventuali relazioni non lineari;
- **categorizzazione della variabile:** suddividere l'età in fasce (es. 18–24, 25–34, 35–44, ...) e introdurre variabili dummy per ciascuna categoria, consentendo al modello di apprendere effetti differenti per ciascun gruppo;
- **funzioni spline:** utilizzare spline lineari o cubic spline per rappresentare in modo flessibile l'andamento non lineare dell'età, mantenendo al contempo una continuità nei punti di raccordo;
- **altri approcci di regolarizzazione o riduzione di dimensionalità:** ad esempio penalizzazioni (ridge, lasso) per evitare overfitting in presenza di molte trasformazioni, oppure tecniche di smooth fitting per controllare la complessità del modello.

Queste trasformazioni permettono di modellare meglio l'effetto dell'età, evitando di imporre una relazione lineare troppo restrittiva e garantendo al tempo stesso una maggiore flessibilità nella costruzione della matrice di transizione.

Tra le diverse strategie illustrate, in questo lavoro si è deciso di adottare la **categorizzazione della variabile età**.

Questa scelta consente di distinguere in modo chiaro le diverse fasce d'età dei donatori, mantenendo al tempo stesso un modello interpretabile. In particolare, le categorie permettono di osservare come il comportamento donazionale vari nei diversi gruppi, evidenziando ad esempio differenze tra i donatori più giovani, quelli in età intermedia e i più anziani.

In questo modo si ottiene un compromesso tra semplicità e capacità di rappresentare l'andamento non lineare della variabile, evitando di introdurre complessità eccessiva tramite spline o polinomi di grado elevato.

Durante la pandemia da coronavirus SARS-CoV-2 la propensione a donare e le sue motivazioni sono cambiate molto. Riteniamo quindi di dovere aggiungere quest'informazione al modello e manipolare la serie storica in questo momento

storico in modo a se stante. Infatti grazie all'introduzione di questa covariate si possono osservare in quegli anni, un profondo cambiamento del trend.

Dataset con le covariate per i GLM

Attraverso le probabilità iniziali e la matrice di transizione possiamo risalire allo stato latente dell'individuo lungo la sua serie storica. Con l'obiettivo di predire il valore atteso della prossima donazione, lo stato latente più importante che ci interesserà conoscere, sarà l'ultimo stato latente, ovvero lo stato che ci dirà quale dei k dei K diversi modelli utilizzare. Il HMM-GLM ha esattamente questo di differenza confronto un normale HMM, l'HMM-GLM non restituisce un *rate*, o il parametro di una qualsiasi distribuzione; ma restituisce l'indicazione a quale modello usare. Infatti, ipotizziamo che il modello generatore dei dati sia significativamente diverso tra i 3 diversi *pattern* di donatori. E non è una differenza fissa/statica, ma una differenza molto più complessa, che è influenzata anche da altri fattori. Per questo, si ritiene opportuno usare 3 modelli diversi per modellare e predire le future donazioni di sangue.

Le covariate scelte in questo caso sono un incrocio tra covariate statiche e dinamiche. Le variabili scelte sono il genere, le fasce d'età e il periodo covid.

Dopodiché si è diviso il dataset iniziale in 4 dataset più piccoli.

- Covariate disponibili: genere (M/F), anno di nascita. Covariate costruite:

- Iniziali $x^\pi \in \mathbb{R}^3$: intercetta, birth_year_norm (z-score), gender_code (F=1, M=0).
- Transizioni $x_t^A \in \mathbb{R}^8$: intercetta; fasce d'età one-hot (baseline 18-24, poi 25-34, 35-44, 45-54, 55-59, 60-64, 65+); indicatore COVID (1 per 2020-2022, 0 altrimenti).
- Emissioni $x_t^{\text{em}} \in \mathbb{R}^9$: intercetta; gender_code; stesse dummies di età; COVID.

[Da integrare: specifica finale e grafico delle fasce d'età.]

3.2.3 Componenti del Modello

Il modello, come citato in Sezione 3.2.1, è definito tramite Pyro. Si ritiene che sia importante esplicitare il codice, tanto quanto la stesura di una formula matematica. Mediante la lettura del codice si comprende a pieno le potenzialità di Pyro e la struttura del modello.

Il numero di stati latenti, K , è stato fissato a 3. Quindi, $z_{n,t} \in \{0, 1, 2\}$, e non sono osservate. La loro interpretazione reale sarà il profilo di donatore, ovvero se sarà un donatore frequente, occasionale o sporadico.

Le osservazioni, $y_{n,t} \in \mathbb{N}$, sono conservate nella variabile `obs`, che è una matrice di dimensione $\mathbb{N}$, $\mathbb{T}$ e assume valori in $[0, 4]$. Come spiegato nel capitolo precedente (vedi Sezione 3.2.2), sono presenti altre tre matrici composte da:

- covariate sulle probabilità iniziali, $W_\pi \in \mathbb{R}^{K \times 2}$;
- covariate sulla matrice di transizione, $W_A \in \mathbb{R}^{K \times K \times 8}$; e
- covariate sulle emissioni, $\beta_{em} \in \mathbb{R}^{K \times (1+9)}$, che in questo caso saranno le covariate dei K diversi modelli.

In Python ci sarà una prima parte di configurazione del modello, con le diverse dimensioni degli oggetti da passare, la scelta del numero di stati.

Approccio Bayesiano

Abbiamo adottato un approccio bayesiano per le componenti che governano le probabilità iniziali e le transizioni dell'HMM, usando prior di tipo Dirichlet sulle intercette e lasciando stimare per MAP (via `pyro.param`) le pendenze che modulano l'effetto delle covariate. In particolare:

- distribuzione iniziale: $\pi_{\text{base}} \sim \text{Dirichlet}(\alpha_\pi)$ con α_π asimmetrica per spezzare la simmetria delle etichette e incorporare la conoscenza a priori sull'elevata prevalenza dello “stato inattivo” (non-donatore), dovuto al fatto che al tempo $t = 0$, ancora molti dei donatori non avevano iniziato a donare;
- matrice di transizione: per ciascuna riga k , $A_{\text{base}}[k, \cdot] \sim \text{Dirichlet}(\alpha_{A_k})$. Abbiamo valutato sia una a priori non informativa (simmetrica) sia una a priori “diagonale” (con massa concentrata sulla permanenza $k \rightarrow k$).

Motivazioni per l'approccio bayesiano:

- identificabilità pratica: una prior asimmetrica su π mitiga il *label switching* e rende più stabile il confronto tra fit riavviati con semi diversi;
- inferenza scalabile: l'uso della variazionale stocastica con enumerazione esatta delle variabili discrete (`TraceEnum_ELBO`) riduce la varianza del gradiente e consente di trattare in modo efficiente le catene latenti $z_{n,t}$ {Hoffman et al. (2013)};
- coerenza interpretativa: la combinazione “prior diagonale” su A e Poisson/Gamma sulle emissioni porta a tre profili comportamentali stabili (non-, leggero, frequente donatore), con transizioni credibili e facilmente comunicabili.

Definizione del modello

Il modello è caratterizzato da due cicli annidati tra loro, uno sul numero di osservazioni e uno sulla serie temporale. Questi cicli sono caratterizzati da un passo base e un passo iterativo. Potremmo definire l'algoritmo così come segue:

Passo base n:

1. campionamento delle a priori e conversione in base logaritmica per le variabili $\pi_{\text{base},k}$ e $A_{\text{base},kj}$
2. calcolo dei coefficienti tramite la matrice delle covariate per i parametri $W_{\pi,k}$, $W_{A,kj}$ e $\beta_{em,k}$.

Passo iterativo n:

Passo base t:

3. Calcolo delle probabilità iniziale dell'individuo,, di iniziare la sua traiettoria nello stato k, tramite la formula

$$\Pr(z_{n,0} = k \mid x_n^\pi) = \text{softmax}_k \left(\log \pi_{\text{base},k} + W_{\pi,k} \cdot x_n^\pi \right)$$

e campionamento dello stato da tali probabilità.

4. Calcolo del parametro $\log(\mu_{n,t}^{\text{em}})$ corrispondente al logaritmo del valore atteso di donare al tempo $t = 0$. Campionamento di y_0 dalla distribuzione di Poisson con il parametro appena calcolato.

Passo iterativo t:

5. Calcolo delle probabilità di transizione al tempo t sfruttando la matrice di transizione calcolata nel passo base di n e pesata per le informazioni che si hanno a disposizione per l'unità n al tempo t . Attraverso questa formula

$$\Pr(z_{n,t} = j \mid z_{n,t-1} = k, x_{n,t}^A) = \text{softmax}_j \left(\log A_{\text{base},kj} + W_{A,kj} \cdot x_{n,t}^A \right)$$

si campiona la probabilità che l'unità n occupi lo stato j al passo t sapendo che al passo $t - 1$ occupava lo stato k .

6. Dato lo stato j , calcolato al punto precedente, campionamento del numero di donazioni al tempo t :

$$y_{n,t} \mid z_{n,t} = k \sim \text{Poisson} \left(\exp \left(X_{n,t}^{\text{em}} \beta_{\text{em},k} \right) \right)$$

Definizione del guide

Il guide specifica la famiglia variazionale $q(\cdot)$ utilizzata da SVI per approssimare la posteriore. Qui scegliamo una approssimazione “a massa puntuale” (Delta) per i soli nodi continui latenti del modello, cioè le intercette della distribuzione iniziale e della matrice di transizione: $q(\pi_{\text{base}}) = \delta(\pi_{\text{base}} - \hat{\pi})$ e $q(A_{\text{base}}) = \delta(A_{\text{base}} - \hat{A})$. Le variabili discrete $z_{n,t}$ non compaiono nel guide perché vengono enumerate esattamente nel modello (`@config_enumerate`), e i coefficienti W_π , W_A , β_{em} sono stimati come parametri deterministici (`pyro.param`). In termini teorici, si massimizza l’ELBO scegliendo una famiglia variazionale degenere (MAP) per π_{base} e A_{base} , in modo da semplificare l’ottimizzazione e stabilizzare l’identificazione. Anche se, in questo modo, non si quantifica l’incertezza.

I vincoli simplex (`dist.constraints.simplex`) garantiscono che $\hat{\pi}$ e ciascuna riga di $\hat{A}$ siano probabilità valide (non negative e a somma unitaria). L’inizializzazione deve già rispettare il vincolo: normalizziamo α_π per ottenere un punto di partenza ammissibile per π_q , mentre per A_q usiamo una matrice “diagonale rinforzata” rinormalizzata per riga, che favorisce la persistenza.

Allenamento del modello

L’addestramento dell’HMM-GLM è stato condotto con un approccio bayesiano variazionale. Il modello principale è stato allenato su tutti i dati, in modo da avere un modello in produzione il più performante possibile. In area di sviluppo, invece, il dataset è stato suddiviso in train/test con split 90/10, stratificando per genere e fascia d’età al tempo iniziale e fissando il seed a 42, per garantire la riproducibilità. Ottenendo cos’ due dataset, il dataset con i dati d’allenamento, *train* $N = 8308$, e il dataset con i dati di test, *test* $N = 928$. Le covariate, come visto anche nella Sezione 3.2.3, sono state progettate in tre blocchi coerenti con le tre componenti del modello: iniziali $x^\pi \in \mathbb{R}^3$ (intercetta, `birth_year_norm` in z-score, `gender_code` $F=1/M=0$), transizioni $x_t^A \in \mathbb{R}^8$ (intercetta; fasce d’età one-hot con baseline 18–24 `age_class`; indicatore `covid_year` per 2020–2022), ed emissioni $x_t^{\text{em}} \in \mathbb{R}^9$ (intercetta; `gender`; stesse dummies d’età; `covid_year`).

i Scelta del numero di parametri

Il numero di stati latenti è stato fissato a $K = 3$ per ragioni di interpretabilità e stabilità numerica. Inoltre, la scelta è stata giustificata anche dal *Bayesian Information Criterion*, BIC Wit, Heuvel, e Romeyn (2012). Il BIC è un criterio per la selezione del modello statistico da usare basato sulla funzione di verosimiglianza ma che viene penalizzato all’aumentare del numero di parametri e dalla scarsità del numero di osservazioni ed è definito come segue:

$$\text{BIC} = k \ln(n) - 2 \ln(\hat{L})$$

dove $\hat{L}$ è la funzione di verosimiglianza, n il numero di osservazioni e k il numero di parametri. Il motivo per la quale si usa il logaritmo sul

numero di osservazioni, $\ln(n)$, è dovuto alla *maledizione delle dimensionalità* (Bellman (1957)): all'aumentare del numero di parametri è necessario un numero esponenzialmente crescente di osservazioni per mantenere invariato il livello di incertezza nelle stime.

Osservando il grafico Figura 3.1, si nota, come il criterio BIC raggiunga il suo massimo con il numero di stati pari a 3. Nel grafico, non viene utilizzata la formula precedentemente descritta, ma una sua variante in modo da comparare facilmente l'assenza dell'utilizzo di un parametro di penalizzazione nella *likelihood* e la sua aggiunta. La formula usata è la seguente:

$$\text{BIC-like} = \ln(\hat{L}) - \frac{1}{2}k \ln(n)$$




Figura 3.1: Log-likelihood e BIC al variare del numero di parametri

L'inferenza è stata eseguita in Pyro tramite *stochastic variational inference* (SVI) con obiettivo ELBO (*Evidence Lower Bound*). Le variabili latenti discrete $z_{n,t}$ sono state enumerate esattamente con `TraceEnum_ELBO(max_plate_nesting=1)`, così da ridurre la varianza del gradiente ed evitare la necessità di campionamento stocastico sugli stati. Il guide variazionale impiega una famiglia degenera (Delta) per le sole intercette, ovvero $q(\pi_{\text{base}}) = \delta(\pi_{\text{base}} - \hat{\pi})$ e $q(A_{\text{base}}) = \delta(A_{\text{base}} - \hat{A})$, mentre le pendenze W_{π} , W_A e i coefficienti β_{em} sono stimati come parametri deterministici (`pyro.param`) in ottica MAP. Questa scelta semplifica l'ottimizzazione e migliora l'identificabilità pratica nelle fasi iniziali del training, a costo di non propagare incertezza sulle intercette.

Dal punto di vista numerico, l'ottimizzazione è stata effettuata con Adam a passo $2 \cdot 10^{-2}$, operando in full-batch per ogni step (tutte le sequenze in una singola plate), in quanto il numero di osservazioni non era eccessivo. Il ciclo di addestramento ha previsto 2000 step; l'ELBO decresce rapidamente nelle prime epoche per poi stabilizzarsi. Al termine, i parametri vengono salvati nel

`ParamStore` per l'uso in produzione e per la riproducibilità (modello in produzione “prod”: `models/hmm_glm_full.pt`; modello per lo sviluppo “dev” per valutazioni su *hold-out*: `models/hmm_glm_train.pt`).

Per contenere i costi computazionali, si osservi che la complessità per step è dell'ordine $\mathcal{O}(NTK^2)$, dominata dalle transizioni $K \times K$ e dall'enumerazione; con $K = 3$ il training è agevole anche su CPU. Tuttavia, il codice è costruito in modo da poter essere girato anche su GPU Nvidia, attraverso l'utilizzo dell'architettura `cuda`, che permetterebbe lo sviluppo in parallelo.

3.3 Risultati

Poiché le tre componenti centrali dell'HMM-GLM sono la distribuzione iniziale sugli stati, la matrice di transizione e l'emissione (GLM di Poisson specifico di stato), presentiamo i risultati scomponendo l'analisi lungo questi assi e distinguendo tra grandezze di “popolazione” (ottenute inserendo valori medi delle covariate) e grandezze “soggetto-specifiche” (ottenute dalle covariate effettive di ciascun donatore).

Per le probabilità iniziali si applica Equazione 3.1:

$$\pi_n = \text{softmax}\left(\log \pi_{\text{base}} + x_n^\pi W_\pi^\top\right), \quad (3.1)$$

dove x_n^π sono le covariate del donatore n . Un riassunto di popolazione si ottiene sostituendo x_n^π con la media campionaria delle covariate (plug-in) e calcolando la corrispondente $\bar{\pi}$. Il grafico in Figura 3.2a mostra che la quota di donatori che, al tempo iniziale, si colloca nello stato “dormiente/non-donatore” (stato 0) è molto elevata (circa 80%). Le restanti masse si ripartiscono tra stato 1 (saltuario, circa 6%) e stato 2 (abituale, circa 12%). Questo esito è coerente con la struttura dei dati, che includono gli anni precedenti alla prima donazione riempiti con zeri (completamento longitudinale), e con la prior asimmetrica su π_{base} che spezza la simmetria delle etichette e riflette l'alta prevalenza iniziale dello stato 0.

La matrice di transizione media in Figura 3.2b evidenzia forte persistenza di stato: la probabilità di permanenza sulla diagonale è alta per tutti e tre gli stati (circa $P(0 \rightarrow 0) \simeq 0,83$, $P(1 \rightarrow 1) \simeq 0,98$, $P(2 \rightarrow 2) \simeq 0,94$), mentre i termini fuori diagonale sono tutti inferiori a circa 0,10. In termini pratici, i passaggi tra profili comportamentali sono rari; ciò vale in media e a parità di covariate, mentre a livello individuale le probabilità di transizione vengono modulate dalle covariate $x_{n,t}^A$ (fasce d'età e indicatore COVID). Si osserva inoltre, a livello di occupazione di stato nella popolazione, uno spostamento di massa dagli stati meno attivi verso quelli più attivi nel 2020–2022, coerente con l'effetto dell'indicatore COVID nelle transizioni (cfr. sezione “Occupancy e switch-rate”).




Figura 3.2: Risultati principali del modello

3.3.1 Coefficienti β_{em}

Per le emissioni non ha senso parlare di “probabilità di donare x nello stato k ” indipendentemente dalle covariate, perché nel nostro HMM-GLM il tasso di Poisson dipende dallo stato e dalle covariate: $\log \lambda_{n,t,k} = x_{n,t}^{em} \cdot \beta_{em}[k, :]$. La lettura più chiara è dunque in termini di coefficienti esponenziati, che rappresentano effetti moltiplicativi sul valore atteso. Il grafico in Figura 3.2c e la tabella Tabella 3.1 riportano, per ciascuno stato, l’intercetta (donatore maschio, 18–24 anni, in periodo non COVID) e i fattori moltiplicativi per genere, età e COVID. In particolare: l’intercetta vale circa 0,01 nello stato 0 (dormiente), 0,84 nello stato 1 (saltuario) e 2,03 nello stato 2 (abituale). Il coefficiente “gender” (<1 in tutti gli stati) implica, a parità di età e periodo, un tasso atteso inferiore per le donne: ad esempio, nello stato 2 una donna 18–24 anni in periodo non COVID ha $2.03 \times 0,56 \approx 1,14$ donazioni attese (-44% rispetto al maschio baseline). Gli effetti d’età sono deboli nello stato 1 (fattori prossimi a 1) e crescenti nello stato 2: per 55–59 anni il moltiplicatore è circa 1,18 e per 60–64 è circa 1,22 (in linea col profilo “abituale” più marcato nelle classi d’età centrali-avanzate). L’indicatore COVID agisce in modo eterogeneo: è >1 nello stato 1 (circa 1,24, “boost” relativo), circa 1 nello stato 2 (circa 0,97, lieve attenuazione/neutralità) e $\gg 1$ nello stato 0 (circa 2,51), ma in quest’ultimo caso l’aumento relativo non si traduce in un incremento assoluto rilevante perché la base (0,01) è molto piccola.

Tabella 3.1: Coefficienti dei modelli GLM per stato elevati all’esponenziale

			age	age	age	age	age	age	
	intercept	gender	[25-34]	[35-44]	[45-54]	[55-59]	[60-64]	[+65]	covid
State 0	0	0.13	0.16	0.11	0.53	10.35	0.59	0.69	2.15
State 1	0.84	0.75	0.92	0.99	1.06	1.08	1.02	0.9	1.24
State 2	2.02	0.56	1.01	1.05	1.11	1.18	1.22	1.15	0.97

Nel complesso, le tre componenti del modello convergono verso un quadro coerente: (i) la maggior parte dei donatori inizia nello stato di bassa attività, (ii) i profili sono altamente persistenti con rari passaggi tra stati, (iii) i GLM per stato catturano differenze interpretabili per genere, età e shock COVID, con un chiaro gradiente di intensità dallo stato 0 (quasi nullo) allo stato 2 (frequente). Per passare dalle letture di popolazione a valutazioni soggetto-specifiche, nella sezione sul Viterbi e sul filtraggio forward mostriamo come le distribuzioni sugli stati e le previsioni one-step-ahead si ottengano combinando le $A_{n,t}$ condizionate alle covariate con i tassi $\lambda_{n,t,k}$ dei GLM di stato.

3.3.2 Coefficienti W_π

Osservando i coefficienti delle probabilità iniziali W_π , si nota come la probabilità che un donatore inizi dallo stato 2 aumenti al crescere dell'anno di nascita, mentre decresce la probabilità di iniziare dallo stato 0 (Figura 3.3b). Per il genere, invece, sarà più probabile che una donatrice inizi dallo stato 0 che dallo stato 2, mentre per lo stato 1 l'effetto è meno accentuato. Come visto nel capitolo introduttivo, nelle analisi preliminari (vedi Sezione 1.2.2), osservando la tabella delle donazioni per genere ed età (vedi Tabella 1.3) si osservava come ci fosse un forte incremento di donazioni da parte delle donatrici più giovani negli ultimi anni. Ciò giustificerebbe i coefficienti presenti in Figura 3.3a.





Figura 3.3: Grafici sui valori dei coefficienti W_π

3.3.3 Coefficienti W_A

Dai coefficienti della matrice di transizione Figura 3.4, si possono trarre diverse osservazioni.

Partendo dalle fasce d'età, e in specifico dalla transizione $0 \rightarrow 0$, si può vedere come la probabilità di rimanere nello stato 0 decresca all'aumentare dell'età, ad eccezione della fascia +65. Infatti, ricordiamo che il limite in Italia per donare sangue è di 65 anni, ad eccezione dei donatori regolari, che è estesa a 70, previa consultazione medica. Infatti aumenta la probabilità delle transizioni $1 \rightarrow 0$ e $2 \rightarrow 1$ nella fascia +65.

Per quanto riguarda l'effetto covid, durante gli anni della pandemia la probabilità delle transizioni $0 \rightarrow 0$, $1 \rightarrow 0$ e $2 \rightarrow 0$ erano minori, invece erano maggiori per le transizioni $0 \rightarrow 1$ e $1 \rightarrow 1$. Si osserva anche che molti donatori frequenti, in quel periodo, hanno ridotto il numero di donazioni ($2 \rightarrow 1$).

Figura 3.4: Coefficienti di W_A

3.4 Algoritmi e diagnostiche

3.4.1 Viterbi con covariate

Nel nostro HMM-GLM le tre componenti dipendono da covariate:

1. la distribuzione iniziale $\pi(x^\pi)$ tramite $\text{softmax}(\log \pi_{\text{base}} + W_\pi x^\pi)$,
2. le transizioni $A(x_t^A)$ tramite $\text{softmax}(\log A_{\text{base}} + \langle W_A, x_t^A \rangle)$ e
3. l'emissione Poisson-GLM per stato k con $\log \lambda_k(t) = x_t^{\text{em}^\top} \beta_{\text{em},k}$.

A parametri fissati (plug-in), il percorso MAP $z_{0:T}^*$ si ottiene per programmazione dinamica, con un passo base e un passo iterativo.

Inizializzazione: tramite l'Equazione 3.2 si ricavano le probabilità per stato al tempo 0. L'emissione $(\log \Pr(y_0 \mid z_0=k))$ è la poisson con parametro $\lambda_k(0) = \exp(x_0^{\text{em}^\top} \beta_{\text{em},k})$.

$$\delta_0(k) = \log \pi_k(x^\pi) + \log \Pr(y_0 \mid z_0=k), \quad (3.2)$$

Ricorsione per $t = 1, \dots, T$: in quest'altro caso l'Equazione 3.3 è data dal massimo della probabilità di stare nello stato precedente, k , sommato alla probabilità di spostarsi al tempo t dallo stato k allo stato j . Successivamente viene sommata la log-probabilità di emissione.

$$\delta_t(j) = \max_k \left\{ \delta_{t-1}(k) + \log A_{k \rightarrow j}(x_t^A) \right\} + \log \Pr(y_t \mid z_t=j), \quad (3.3)$$

Backtracking: è più semplice del passo *forward*, in questo caso bisognerà cercare l'argomento che massimizza la funzione δ .

$$z_T^* = \arg \max_j \delta_T(j), \quad z_{t-1}^* = \psi_t(z_t^*) \quad (t = T, \dots, 1). \quad (3.4)$$

Occupancy e Switch-rate

Con l'algoritmo appena descritto, andiamo a calcolare per ogni donatore nel nostro dataset la sue serie temporale attesa di stati latenti e rappresentiamo in un grafico (vedi Figura 3.5) la loro distribuzione lungo gli anni. I risultati mostrano come lo stato 2, ovvero dei donatori frequenti è abbastanza stabile e in leggero aumento. Mentre, si nota come durante la pandemia ci sia stato un notevole spostamento dallo stato 0 (non donatore) allo stato 1 (donatore saltuario). Ciò è stato confermato nella sezione precedente (Sezione 3.3.3) dove attraverso il grafico dei coefficienti della matrice di transizione W_A si osservava (vedi Figura 3.4) come la probabilità di passare dallo stato 0 a uno stato superiore fosse molto maggiore che in un periodo in assenza della pandemia.




Figura 3.5: Occupazione degli stati per anno

3.4.2 Forward per log-likelihood

Data una serie di osservazioni, ovvero di donazioni e un set di informazioni demografiche sull'individuo, il nostro scopo sarà quello di prevedere il numero di donazioni all'anno successivo, dunque il suo stato latente al tempo $T + 1$.

La forward recursion fornisce la log-verosimiglianza e la distribuzione filtrata sugli stati, utile per la previsione one-step-ahead. Definendo $\alpha_t(j) = \Pr(z_t=j \mid y_{0:t})$ (fino a normalizzazione), si ha:

Filtering

$$\tilde{\alpha}_t(j) = \Pr(y_t \mid z_t=j) \sum_k \alpha_{t-1}(k) A_{k \rightarrow j}(x_t^A),$$

$$\alpha_t(j) = \frac{\tilde{\alpha}_t(j)}{\sum_h \tilde{\alpha}_t(h)}.$$

Tabella 3.3: Probabilità di appartenere allo stato k in $T + 1$

State	0	1	2
Next-state probabilities:	0.005	0.125	0.870

Tabella 3.4: Probabilità delle donazioni future

# donations	0	1	2	3	4
Probability	0.175	0.275	0.252	0.164	0.131
Expected next donations:	1.871				
Prob donate next:	0.824				

In Figura 3.6 si possono vedere degli esempi su donatori che seguono traiettorie ben distinte tra loro. Il modello è capace di seguire le loro traiettorie e adattarsi in eventuali cambi di comportamento del donatore. In Figura 3.6d, il modello è *dormiente* fino alla sua prima donazione per poi assegnare al donatore lo stato 2, ovvero di donatore frequente. In Figura 3.6a, invece, il donatore inizia da uno stato 2 per poi passare nel tempo a un calo nel numero di donazioni annue, ed il suo stato mutua da 2 a 1. Alla fine di ciascun grafico è presente il numero di donazioni predetto dal modello e il numero di donazioni effettivamente effettuate all'anno $T + 1$.

3.4.3 Calibrazione e confronto con GLM

Valutazione one-step-ahead su test hold-out (90/10 stratificato):

- Mean log-likelihood per sequenza circa -13.05 (test), -13.47 (train);
- MAE circa 0.51; RMSE circa 0.77; Brier per $I\{y > 0\}$ circa 0.18; NLL circa 0.88 (test).

Confronto con GLM Poisson “vanilla”:

- GLM: pred mean 0.96 (obs 0.91), MSE 1.016, accuracy(round) 28.2%;
- HMM mixture mean non filtrato: pred mean 0.55, MSE 1.248, accuracy(round) 40.0%.

Interpretazione: senza filtraggio, la mistura di Poisson è conservativa sul livello medio ma migliora l'accuracy su conteggi arrotondati; con filtraggio (uso di α_T) la calibrazione di $P(y > 0)$ è buona (Brier circa 0.18).




Figura 3.6: Predizione del numero di donazioni per diversi profili di donatore

Lista 3.1 Definizione del modello in Pyro

```

K      = 3          # Number of latent states
C_pi   = cov_init.shape[1]      # Initial-state covariates (birth_year_norm, gender)
C_A    = cov_tran.shape[2]      # Transition covariates (ages_norm, covid_years)
C_em   = cov_emission.shape[2]  # Emission covariates (gender, 7 age dummies, c

# Dirichlet prior
alpha_pi = torch.tensor([5., 2., 1.])
alpha_A  = torch.ones((K, K))

@config_enumerate
def model(obs, x_pi, x_A, x_em):
    N, T = obs.shape

    # 1) Priors/parameters for initial and transition distribution
    pi_base = pyro.sample("pi_base", dist.Dirichlet(alpha_pi))          # [K]
    A_base  = pyro.sample("A_base", dist.Dirichlet(alpha_A).to_event(1)) # [K, K]
    log_pi_base = pi_base.log()
    log_A_base  = A_base.log()

    # 2) Slope coefficients for initial and transition covariates
    # and State-specific GLM emission coefficients (learned)
    W_pi = pyro.param("W_pi", torch.zeros(K, C_pi))                    # [K, C_pi]
    W_A  = pyro.param("W_A", torch.zeros(K, K, C_A))                    # [K, K, C_A]
    beta_em = pyro.param("beta_em", torch.zeros(K, C_em))               # [K, C_em+1]

    with pyro.plate("seqs", N):
        # Initial hidden state probabilities: depend on x_pi via W_pi
        logits0 = log_pi_base + (x_pi @ W_pi.T)                          # [N, K]
        z_prev = pyro.sample("z_0",
                              dist.Categorical(logits=logits0),
                              infer={"enumerate": "parallel"})

        # Emission at t=0: state-specific GLM on covariates x_em[:, 0, :]
        log_mu0 = (x_em[:, 0, :] * beta_em[z_prev, :]).sum(-1)
        pyro.sample("y_0", dist.Poisson(log_mu0.exp()), obs=obs[:, 0])

        # For t = 1 ... T-1, update state and emit
        for t in range(1, T):
            x_t = x_A[:, t, :]                                           # [N, C_A]
            logitsT = (log_A_base[z_prev] + (W_A[z_prev] * x_t[:, None, :]).sum(-1)
            z_t = pyro.sample(f"z_{t}",
                              dist.Categorical(logits=logitsT),
                              infer={"enumerate": "parallel"})

            # Emission: state-specific GLM at time t
            log_mu_t = (x_em[:, t, :] * beta_em[z_t, :]).sum(-1)
            pyro.sample(f"y_{t}", dist.Poisson(log_mu_t.exp()), obs=obs[:, t])
            z_prev = z_t

```

Lista 3.2 Definizione del Guide in Pyro

```
def guide(obs, x_pi, x_A, x_em):
    pi_q = pyro.param(
        "pi_base_map",
        alpha_pi,
        constraint=dist.constraints.simplex
    )

    # Each row: simplex for state-to-state transitions
    A_init = torch.eye(K) * (K - 1.) + 1.
    A_init = A_init / A_init.sum(-1, keepdim=True)
    A_q = pyro.param(
        "A_base_map",
        A_init,
        constraint=dist.constraints.simplex
    )

    pyro.sample("pi_base", dist.Delta(pi_q).to_event(1))
    pyro.sample("A_base", dist.Delta(A_q).to_event(2))
```

Lista 3.3 Allenamento del modello

```
pyro.clear_param_store()
svi = SVI(model, guide,
          Adam({"lr": 2e-2}),
          loss=TraceEnum_ELBO(max_plate_nesting=1))

for step in range(2000):
    loss = svi.step(obs_torch, cov_init_torch, cov_tran_torch, cov_emiss_torch)
    if step % 200 == 0:
        print(f"{step:4d}  ELBO = {loss:,.0f}")

param_path = here("models/hmm_glm_full.pt")
pyro.get_param_store().save(param_path)
print(f"ParamStore saved in: {param_path}")
```

4 Dashboard e Sito Web

4.1 Motivazione

Lo scopo della tesi non è solo lo studio e l'analisi di un fenomeno da parte del candidato. La tesi in questione si propone come soluzione a un problema reale. Essa unisce la teoria alla pratica, il prodotto dev'essere qualcosa di tangibile e facilmente usufruibile. Se per il modello esplicativo è sufficiente esporre graficamente o tabularmente i risultati, per il modello predittivo bisogna fare qualcosa di più, bisogna creare uno strumento *on demand*, che funzioni in tempo reale. Come dice il nome stesso, lo scopo del modello predittivo è quello di calcolare il valore che ci si attende da una variabile data delle variabili di input. Il calcolo può essere svolto manualmente per un GLM, ma già per un modello come l'HMM-GLM visto nel capitolo precedente, il suo calcolo diventa notevolmente più complesso e l'utilizzo di un calcolatore risulta strettamente necessario.

La dashboard si propone, quindi, come il calcolatore da utilizzare. Dovrà rappresentare qualcosa di complesso in modo semplice e di facile utilizzo. Lo strumento che si andrà a costruire è pensato per il personale medico, in modo da valutare la *retention* degli attuali donatori e fare stime sui loro flussi futuri. Sarà possibile utilizzare la dashboard da un qualsiasi dispositivo, che sia un computer o un telefono, infatti sarà disponibile online e i calcoli verranno eseguiti da un server.

4.2 Sviluppo

Come il sito web, ospitante la tesi, anche la dashboard è sviluppata attraverso il *framework* **Quarto**: un sistema open-source di *publishing* tecnico scientifico che permette di sviluppare progetti in diversi formati contemporaneamente agevolando l'interazione tra diversi linguaggi di programmazione.

Nell'ambito delle dashboard **Quarto** si occupa maggiormente della parte *front-end*, ovvero dell'interfaccia grafica. Quarto trasforma dei documenti in stile markdown in eleganti UI (*User Interface*) in HTML, ottimizzati anche per la visualizzazione da dispositivi mobili.

Per la parte di *back-end*, ovvero la parte di server, il sistema utilizzato è **Shiny**. Shiny è sviluppato principalmente per R, ma supporta anche Python e allo scopo di questo progetto verrà utilizzata la versione *Shiny for Python*.

I modelli e i dati sono già stati elaborati in precedenza in specifici file Python o Jupyter notebook. Riducendo così il tempo di apertura dell'applicazione.

5 Conclusioni

5.1 Risultati

5.2 Idee per il Futuro

- **Hierarchical HMM** per distinguere tipologia di emocomponenti (sangue intero, plasma, piastrine).

Riferimenti

- Bellman, Richard Ernest. 1957. *Dynamic Programming*. Princeton University Press. <https://books.google.com/books?id=wdtoPwAACAAJ>.
- Bingham, Eli, Jonathan P. Chen, Martin Jankowiak, Fritz Obermeyer, Neeraj Pradhan, Theofanis Karaletsos, Rohit Singh, Paul Szerlip, Paul Horsfall, e Noah D. Goodman. 2018. «Pyro: Deep Universal Probabilistic Programming». *Journal of Machine Learning Research*.
- Bordandini, Paola. 2025. «Geografie del capitale sociale. Trent'anni di senso civico in Italia». Riccardo Prandini. <https://cris.unibo.it/retrieve/ee59ddb4-bdeb-4be5-8d2e-e70467252248/Donazioni%20di%20sangue.pdf>.
- Caselli, Graziella, Jacques Vallin, e Guillaume Wunsch. 2006. *Demografia. Analisi e sintesi*. Bologna: Il Mulino.
- Fan, Jieyu. 2015. «On Markov and Hidden Markov Models with Applications to Trajectories».
- Guglielmetti Mugion, Roberta, Maria Giovina Pasca, Laura Di Pietro, e Maria Francesca Renzi. 2021. «Promoting the propensity for blood donation through the understanding of its determinants». *BMC Health Services Research* 21 (1): 127. <https://doi.org/10.1186/s12913-021-06134-8>.
- Hoffman, Matthew D., David M. Blei, Chong Wang, e John Paisley. 2013. «Stochastic Variational Inference». *Journal of Machine Learning Research*.
- ISTAT. 2023a. «Bilancio demografico e popolazione residente: definizioni e note metodologiche». Roma: Istituto Nazionale di Statistica.
- . 2023b. «Tavole di mortalità della popolazione residente: metodi e note tecniche». Roma: Istituto Nazionale di Statistica.
- James, Gareth, Daniela Witten, Trevor Hastie, e Robert Tibshirani. 2013. *An Introduction to Statistical Learning*. Springer.
- Levin, David A., Yuval Peres, e Elizabeth L. Wilmer. 2009. *Markov Chains and Mixing Times*. American Mathematical Society.
- Nomisma. 2024. «Osservatorio Nazionale Donazione Sangue e Plasma». <https://www.nomisma.it/press-area/osservatorio-nazionale-donazione-sangue-e-plasma/>.
- Pati, Ilaria, Claudio Velati, Carlo Mengoli, Massimo Franchini, Francesca Masiello, Giuseppe Marano, Eva Veropalumbo, et al. 2021. «A forecasting model to estimate the drop in blood supplies during the SARS-CoV-2 pandemic in Italy». *Transfusion Medicine* 31 (marzo): 200–205. <https://doi.org/10.1111/tme.12764>.
- Saturni, Vincenzo, Giorgio Fiorentini, e Elisa Ricciuti. 2017. *La Vis di Avis: La Valutazione di Impatto Economico e Sociale dell'Associazione Volontari Italiani del Sangue*. FrancoAngeli.
- Wit, Ernst, Edwin van den Heuvel, e Jan-Willem Romeyn. 2012. «"All models are

wrong...": an introduction to model uncertainty». *Statistica Neerlandica* 66 (3): 217–36. <https://doi.org/10.1111/j.1467-9574.2012.00530.x>.