

Modellazione statistica delle donazioni di sangue nella provincia di Trieste

Invalid Date

La ricerca studia i registri dei donatori di sangue di Trieste (2009-2023) per stimare le caratteristiche dei donatori e predire il loro comportamento futuro.

Su questo pannello longitudinale vengono applicati:

- (i) modelli di regressione quasi-Poisson, tweedie e Gamma per spiegare il numero totale di donazioni effettuate da ciascun individuo;
- (ii) Hidden Markov Models con covariate trattate in modo Bayesiano per descrivere traiettorie latenti di comportamento donativo, e studiare come le covariate influenzino tali stati latenti.



UNIVERSITÀ DEGLI STUDI DI TRIESTE

DIPARTIMENTO DI SCIENZE ECONOMICHE, AZIENDALI,
MATEMATICHE E STATISTICHE "BRUNO DE FINETTI"

Laurea Magistrale in Scienze Statistiche Attuariali

title

Relatore:

Prof: Leonardo Egidì

Candidato:

author

ANNO ACCADEMICO 2021/2022

Indice

1	Blood Donation Predictor	11
	Prefazione	13
2	Introduzione	15
2.1	I Dati	16
2.1.1	Fonte ed Elaborazione	18
2.1.2	Analisi Preliminare	19
2.2	Integrazione dei Dati	19
2.2.1	Stima dei Residenti Passati	20
2.2.2	Unione dei Dati	20
2.3	Risultati preliminari	21
3	Modelli Lineari Generalizzati	23
3.1	Teoria dei GLM	23
3.2	Modello Esplicativo	25
3.2.1	Quasi-Poisson	26
3.2.2	Tweedie ($power \sim 1.19$)	27
3.2.3	Gamma	28
3.3	Modello Predittivo	29
3.3.1	Effetto Covid	29
3.3.2	Modello finale	29
4	Bayesians Hidden Markov Models	31
4.1	Accenni di Teoria	31
4.1.1	Processo Markoviano	31
4.2.1	HMM	32
4.2.2	Modelli Bayesiani	32
4.2.3	Variational Inference	32
4.2.4	Algoritmo Viterbi	32
4.3	Scelta del Numero di Stati Latenti	32
4.4	Il Modello	32
4.5	Diagnostiche	33
4.6	Previsioni	33
5	Dashboard	35
6	Dashboard	37
6.1	Motivazione	37

6.2	Sviluppo	37
7	Conclusioni	39
7.1	Risultati	39
7.2	Idee per il Futuro	39

Elenco delle Figure

1 Blood Donation Predictor

La ricerca studia i registri dei donatori di sangue di Trieste (2009-2023) per stimare le caratteristiche dei donatori e predire il loro comportamento futuro.

Su questo pannello longitudinale vengono applicati:

- 1) modelli di regressione quasi-Poisson, tweedie e Gamma per spiegare il numero totale di donazioni effettuate da ciascun individuo;
- 2) Hidden Markov Models con covariate trattate in modo Bayesiano per descrivere traiettorie latenti di comportamento donativo, e studiare come le covariate influenzino tali stati latenti.

Prefazione

 Avviso

Not ready yet. Come back at the end of september

2 Introduzione

L'obiettivo di questa tesi è proporre — e validare empiricamente — un framework statistico per la previsione delle donazioni di sangue nel territorio Giuliano-Isontino, con orizzonte annuale.

La scelta di concentrare l'analisi sulla provincia di Trieste è motivata da tre fattori:

1. **Alta densità di donatori rispetto alla popolazione residente:** il territorio triestino è storicamente virtuoso nella raccolta di sangue; ciò rende disponibili serie temporali lunghe e relativamente complete.
2. **Stabilità del bacino d'utenza:** la popolazione residente ha oscillazioni demografiche contenute, riducendo la variabilità “esterna” dovuta a migrazioni massicce. A differenza di grandi città, come Milano e Roma dove i flussi migratori sono hanno un impatto maggiore.
3. **Accesso a dati granulari:** l'ASUGI ha messo a disposizione un estratto anonimo dei registri donatori 2009-2023 che, pur privo di variabili sensibili, contiene informazioni anagrafiche e cronologia donativa sufficienti per la modellazione.

Nella pratica quotidiana i centri trasfusionali devono rispondere alla domanda clinica garantendo un buffer di scorte: sovrastimare i lotti in scadenza comporta costi di smaltimento, mentre sottostimare la raccolta può generare situazioni critiche con rinvii di interventi chirurgici programmati.

Pertanto, è cruciale disporre di **strumenti predittivi** che stimino:

- la probabilità che un donatore torni a donare l'anno successivo;
- la distribuzione del numero di donazioni attese per singolo individuo;
- i profili latenti di comportamento (frequente, saltuario, non-donatore, ecc.) e la loro evoluzione nel tempo.

A fronte di tali esigenze la tesi si articola in due nuclei metodologici:

1. **Generalized Linear Models (GLM)** per stimare il numero *cumulato* di donazioni nell'orizzonte storico, con diverse famiglie di distribuzione (quasi-Poisson, Tweedie, Gamma).

2. **Hidden Markov Models bayesiani** con covariate, in cui il numero di donazioni annue è trattato come emissione di una variabile di stato latente.

Il fitting è condotto mediante Variational Inference (Pyro), consentendo di gestire milioni di osservazioni con tempi computazionali compatibili al problema.

A corredo dei modelli è stata sviluppata una **dashboard interattiva Quarto + Shiny** che consente al personale medico di:

- filtrare la popolazione (età, genere, anno di prima donazione, ecc.);
- visualizzare la probabilità di transizione fra stati latenti;

2.1 I Dati

In Italia possono donare sangue le persone di età compresa tra i 18 e i 65 anni, con un peso corporeo superiore ai 50 kg e in buono stato di salute. Gli uomini e le donne non in età fertile possono donare sangue intero ogni 3 mesi, mentre le donne in età fertile possono farlo 2 volte l'anno.

La donazione di sangue nel contesto italiano è il frutto di un sistema dove stakeholder del settore pubblico (regioni, centri ospedalieri), privato (associazioni non profit) e cittadini contribuiscono attivamente al buon esito di questo processo (Guglielmetti Mugion et al., 2021). La creazione del Centro Nazionale Sangue (CNS) e del Registro nazionale del sangue nel 2007 ha trasformato l'assetto organizzativo della donazione del sangue in Italia. Il CNS è stato istituito con Decreto del Ministro della Salute del 26 aprile 2007 e ha iniziato il suo mandato il 1° agosto dello stesso anno. Il CNS svolge funzioni di coordinamento e controllo tecnico-scientifico del sistema trasfusionale nazionale nelle materie disciplinate dalla legge n. 219 del 21 ottobre 2005 “Nuova disciplina delle attività trasfusionali e della produzione nazionale degli emoderivati” e dai decreti di trasposizione delle direttive europee. All'interno di tale sistema sono presenti le Strutture Regionali di Coordinamento per le attività trasfusionali (SRC). Le SRC sono strutture tecnico-organizzative delle Regioni e Province Autonome che garantiscono il supporto alla programmazione nazionale in materia di attività trasfusionali e il coordinamento e controllo tecnico-scientifico della rete trasfusionale regionale, in sinergia con il Centro Nazionale Sangue. Queste strutture regionali, anche definite Centri Regionali Sangue, detengono la responsabilità della raccolta e gestione delle donazioni di sangue a livello regionale.

Nel corso degli anni, il Ministero della Salute ha visto un significativo supporto dalle associazioni attive nel campo delle donazioni, come AVIS (Associazioni Volontari Italiani Sangue), FRATRES (Consociazione Nazionale dei Gruppi Donatori di Sangue Fratres delle Misericordie d'Italia), FIDAS (Federazione Italiana Associazioni Donatori di Sangue), Croce Rossa Italiana. Queste organizzazioni svolgono un ruolo cruciale nel promuovere attivamente la pratica della donazione del sangue: sebbene la decisione di donare sia una scelta individuale, è infatti importante sottolineare

il ruolo essenziale che esse svolgono nell'informare e nel fungere da ponte tra le istituzioni (scuole incluse) e i cittadini. La pratica del dono del sangue, peraltro, produce capitale sociale non solo per il dono di una parte di sé in quanto tale, ma anche grazie alla partecipazione sociale all'interno delle organizzazioni che la promuovono.

La letteratura riguardante il dono nel sangue nel contesto italiano si è concentrata principalmente sui donatori e sulle motivazioni al dono. Molte delle ricerche sono state svolte in collaborazione con l'AVIS, probabilmente perché la raccolta di informazioni riguardanti le unità di sangue donate si è sistematizzata a livello nazionale solo dal 2007 con l'istituzione del CNS e la creazione del registro nazionale sangue, come descritto poc'anzi. Le ricerche hanno sovente utilizzato dati raccolti intervistando i donatori (sia attraverso strumenti standardizzati, sia con approcci di tipo qualitativo). Nei prossimi paragrafi utilizzeremo i dati sulle donazioni di sangue a livello territoriale, ma prima di entrare nel dettaglio sulle differenze geografiche delle donazioni di sangue pare opportuna una sintetica ricognizione sui principali aspetti emergenti da tali ricerche condotte nel contesto italiano.

Un'analisi approfondita condotta da Lacetera e Macis (2013) sui dati AVIS relativi al periodo 1983-2006, focalizzata su una città del centro-nord Italia, ha quantificato l'impatto della Legge 584 del 1967, che ha stabilito il riconoscimento del diritto a una giornata di riposo dal lavoro e alla piena retribuzione al donatore di sangue, sulle pratiche di donazione. Lo studio ha rilevato che l'applicazione di tale normativa ha indotto i donatori a effettuare, in media, una donazione aggiuntiva all'anno. Attraverso un'analisi comparativa delle frequenze di donazione associate ai diversi stati occupazionali assunti dal medesimo individuo, i ricercatori hanno evidenziato una correlazione significativa tra l'occupazione e la propensione alla donazione.

I risultati hanno dimostrato che, in media, quando un individuo è occupato e quindi idoneo a beneficiare dell'incentivo del giorno di riposo retribuito, la frequenza annuale delle donazioni aumenta di circa un'unità rispetto ai periodi di non occupazione.

La decisione di donare sangue è fortemente influenzata da fattori personali e sociali. Una ricerca condotta a Bergamo nel 2006 (Bani, Strepparava, 2011) ha mostrato che il 50% dei donatori è stato motivato dal confronto con amici e familiari, ma anche l'aver ricevuto trasfusioni o conoscere qualcuno che ha beneficiato di una trasfusione hanno avuto un impatto significativo, aumentando la frequenza delle donazioni e la propensione a persuadere altri a donare. Questi risultati evidenziano l'importanza delle relazioni personali e delle esperienze dirette nella promozione della donazione di sangue, confermando il forte legame emotivo e sociale che spinge le persone a donare.

Anche il lavoro delle associazioni, come ricordato, è fondamentale. Esse contribuiscono all'incremento di capitale sociale sia costruendo relazioni con le istituzioni locali, sia creando partecipazione e attivazione attraverso diverse iniziative che mirano allo sviluppo di senso di comunità e appartenenza (Saturni, 2013).

I giovani che partecipano all'AVIS (Bassi et al., 2024), percepiscono l'associazione non solo come un'opportunità per donare il sangue, ma anche come un punto di

riferimento fondamentale per la comunità. All'interno della ricerca di Bassi e colleghi gli intervistati sottolineano il ruolo dell'AVIS come infrastruttura sociale capace di promuovere la coesione e l'inclusione. Essi vedono nel volontariato un'occasione per tessere relazioni, costruire reti e contribuire attivamente alla vita della comunità, confermando così l'importanza delle associazioni come presidi territoriali e promotori del capitale sociale. (Bordandini 2025)

2.1.1 Fonte ed Elaborazione

I dati provengono dall'estrazione e anonimizzazione di dati provenienti dal data warehouse dell'Azienda Sanitaria Universitaria Giuliano Isontina (ASUGI). I dati vengono forniti in formato Il dataset primario proviene dal sistema informativo dei centri trasfusionali dell'ASUGI e contiene le donazioni fatte da un individuo in un determinato anno, corredate di ulteriori informazioni, riportate di seguito:

campo	descrizione
<code>donor_class</code>	classificazione del donatore
<code>donation_type</code>	categoria (SANGUE, PLASMA, PIASTRINE, ...)
<code>birth_year</code>	anno di nascita
<code>birth_cohort</code>	coorte di nascita, generazione (1970, 1975, 1980, ...)
<code>first_donation_year</code>	anno della prima donazione registrata
<code>first_donation_cohort</code>	coorte della prima donazione registrata
<code>number of donations</code>	numero di donazioni effettuate nel determinato anno
<code>gender</code>	M/F
<code>year</code>	anno di riferimento delle donazioni
<code>age</code>	età del donatore
<code>unique_number</code>	identificativo anonimo del donatore

Anche se i dati provengono da un datawarehouse che rispetta protocolli nella gestione del dato, è comunque necessaria una fase di *ETL* (Extract, Transform, Load). Ovvero l'estrazione e la trasformazione del dato in modo da adattarlo e arricchirlo ai nostri scopi specifici. Il lavoro viene svolto mediante il linguaggio di programmazione statistica R, e la libreria `tidyverse`, una libreria contenente funzioni per la manipolazione dei dati garantendo leggibilità del codice e velocità d'esecuzione.

I passi principali compiuti sono i seguenti:

- rimozione record duplicati (`janitor::get_dupes`);
- sostituzione di NA con 0 nei conteggi annuali;
- derivazione di età = `year - birth_year` e classi d'età quinquennali;
- standardizzazione (z-score) di `birth_year` e `age` per facilitare la convergenza dell'ottimizzatore nei modelli bayesiani;

- aggiunta della variabile dummy Covid;
- creazione di **tre matrici di covariate**:
 - x^π (fisse per donatore): anno di nascita e genere;
 - x_t^A (tempo-varianti): età categorica e dummy Covid;
 - x_t^{em} (tempo-varianti): età categorica, dummy Covid e genere.

La derivazione dell'età sarà utile per avere una variabile dinamica, che varia nel tempo. Infatti si presuppone che la propensione al donare vari con l'età del donatore, ed avendo osservazioni pluriennali, si ritiene opportuno tenere in considerazione ciò. Però, anche il fattore generazionale può influire, ovvero una persona di 50 anni del 1970 può avere una propensione nel donare diversa di un cinquantenne nato 10 anni prima. Questo potrebbe essere dovuto da fattori generazionali e anch'esso andrà incluso nelle analisi. Infine, in molte analisi condotte, è stata utilizzata la variabile età come categoriale, anziché numerica.

Nei primi 10 giorni di marzo 2020, all'inizio della pandemia SARS-CoV-2, le donazioni di sangue in Italia sono state quasi nulle, per poi passare ad un forte aumento. Il Centro Nazionale Sangue (CNS), l'autorità nazionale competente, pubblicò linee guida chiare per permettere la continuazione dei prelievi di sangue ed evitare un'interruzione della catena di approvvigionamento della raccolta di materiale trasfusionale. (Pati et al. 2021)

2.1.2 Analisi Preliminare

- Distribuzione fortemente asimmetrica: il 73 % dei donatori effettua 1-2 prelievi/anno, solo l'1 % arriva a 4.
- Trend 2009-2019 crescente (+8 %), brusco calo 2020 (-22 %) per effetto lockdown, graduale recupero 2021-23.
- Moda età 46 - 55 anni, con shift progressivo verso classi d'età superiori (invecchiamento della base, effetto *baby boom*).

2.2 Integrazione dei Dati

Le analisi eseguite finora sono state condotte sui donatori e le loro donazioni, mostrandoci caratteristiche e pattern fondamentali sulle donazioni. Tuttavia, per un'analisi più approfondita è necessario tenere in considerazione anche quella parte di popolazione che non dona, e che, di conseguenza, non risulta essere presente nei dati a noi disponibili.

L'obiettivo è di integrare il database che possediamo con ulteriori informazioni che potrebbero arricchire le analisi e aggiungere informazioni ai modelli.

I dati in nostro possesso sono la raccolta delle donazioni presso le strutture sanitarie dell'ASUGI, ovvero dell'Azienda Sanitaria Universitaria Giuliano Isontina, ovvero che i dati in nostro possesso provengono dai centri trasfusionali del territorio di Trieste e Gorizia. Tuttavia, ciò non indica che le donazioni provengano da cittadini residenti nel territorio Giuliano-Isontino. Infatti, le donazioni sono aperte a tutti, anche a cittadini stranieri, come potrebbe essere uno studente durante il suo progetto Erasmus a Trieste. Andranno fatto, quindi, delle assunzioni per semplificare la realtà. Si ipotizza che le donazioni provengano solo da residenti del territorio. Possiamo allora integrare i dati con le informazioni sui residenti.

Le informazioni provengono dal database pubblico dell'Istituto Nazionale di Statistica, ISTAT. I dati in formato tabulare contengono informazioni di vario genere, tra cui il genere, l'anno, la popolazione e lo stato civile. I dati vengono quindi processati e adattati ai dati sulle donazioni di sangue.

2.2.1 Stima dei Residenti Passati

L'ISTAT fornisce serie 2019-2023 per popolazione residente per età $\times$ sesso.

Per retro-proiettare la popolazione 2009-2018 si applica il **metodo “reverse life-table”**:

$$n_x^{y_i} = n_{x-(y_i-y_j)}^{y_j} \frac{l_x}{l_{x-(y_i-y_j)}},$$

dove l_x è il sopravvivate al'età x nella tavola di mortalità italiane SIM/SIF 02.

Ipotesi: flussi migratori netti costanti e trascurabili nell'intervallo 2009-2019.

2.2.2 Unione dei Dati

La join tra donatori e residenti dà origine a indicatori di penetrazione:

$$\text{penetration}_{a,y,g} = \frac{\# \text{ donatori}(a, y, g)}{\text{residenti}(a, y, g)}, \quad g \in \{F, M\}, \quad a = \text{classe età}, \quad y.$$

Emerge come il tasso di donazione sia massimo nella fascia 30-39 anni (7 ‰) e diminuisca oltre i 60 anni (<2 ‰).

2.3 Risultati preliminari

Nel 2002, Cartocci riportava un valore di donazione pari a 384 ogni 10.000 abitanti; i dati in possesso di Paola Bordandini (Bordandini 2025) mostrano un incremento significativo, con un valore di 438 nel 2009 e un ulteriore aumento fino a 454 nel 2022. Dalle nostre stime, risulta che a Trieste, ...

3 Modelli Lineari Generalizzati

3.1 Teoria dei GLM

I modelli lineari generalizzati (GLM) sono un'estensione dei modelli di regressione lineare. Per comprendere appieno il significato di *Generalized Linear Model*, è utile scomporre il termine.

Iniziamo da *Model*: si tratta di una rappresentazione matematica di un processo che genera dati, ovvero una semplificazione della realtà basata su assunzioni probabilistiche. L'obiettivo è spiegare una variabile dipendente, Y , attraverso delle variabili indipendenti, X , che siano correlate con essa. Una correlazione tra X e Y implica che $COV(X, Y) \neq 0$, dove la covarianza è definita come:

$$COV(X, Y) = E[(X - E[X])(Y - E[Y])] = E[XY] - E[X]E[Y]$$

La correlazione tra due variabili casuali X e Y è definita come:

$$\rho_{XY} = \frac{COV(X, Y)}{\sigma_X \sigma_Y}$$

dove σ_X e σ_Y sono le deviazioni standard di X e Y , rispettivamente.

Consiglio

A causa della moltitudine di applicazioni in diversi ambiti della regressione lineare, non c'è una definizione univoca dei suoi elementi. Nel testo sarà comune, quindi, chiamare la variabile Y come variabile dipendente, *outcome*, *output* o *target*. Stesso problema con la variabile, o le variabili, X , che possono essere chiamate variabili indipendenti, covariate, *features*, predittori o *inputs*.

Quando si desidera esaminare la relazione tra X e Y , spesso si utilizza la regressione lineare, che si propone di spiegare la relazione tra Y e X . La funzione di regressione di Y su X , denotata come $E[Y|X]$, rappresenta il valore atteso di Y dato X . Nella regressione lineare semplice, questa funzione è espressa come:

$$E[Y|X] = \alpha + \beta X$$

dove α è l'intercetta e β è il coefficiente di regressione, calcolato come:

$$\beta = \frac{COV(X, Y)}{VAR(X)}$$

e l'intercetta α è calcolata come:

$$\alpha = E[Y] - \beta E[X]$$

Questa equazione rappresenta la migliore stima lineare di Y dato X secondo il criterio dei minimi quadrati.

i Nota

Se si considerasse l'intercetta nella matrice di covariate X , allora il termine α scomparirebbe e si potrebbe scrivere l'equazione come

$$Y = X\beta + \varepsilon, \quad \varepsilon \sim N(0, \sigma^2)$$

Per la stima di β bisognerà minimizzare l'errore quadratico medio (MSE - *Mean Square Error*) per il criterio dei minimi quadrati (LSE - *Least Squared Error*):

$$MSE = (Y - X\beta)'(Y - X\beta)$$

Bisognerà trovare quindi l'argomento β che minimizzi l'MSE ed è risolto da:

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

Linear indica la linearità nei parametri. Infatti, la funzione di regressione lineare è lineare rispetto ai parametri α e β , anche se la relazione tra X e Y non deve necessariamente essere lineare. Nei modelli lineari generalizzati (GLM), la variabile dipendente Y è modellata seguendo una distribuzione appartenente alla famiglia esponenziale. Una distribuzione è parte della famiglia esponenziale se la sua funzione di densità di probabilità (o funzione di massa di probabilità, nel caso discreto) può essere espressa nella forma:

$$f_Y(y|\theta, \phi) = \exp \left(\frac{y\theta - b(\theta)}{\phi} + c(y, \phi) \right)$$

dove: - θ è il parametro naturale della distribuzione, - ϕ è il parametro di dispersione, - $b(\theta)$ è una funzione che determina la forma della distribuzione, - $c(y, \phi)$ è una funzione che non dipende da θ .

Questa forma generale include molte distribuzioni comuni, come:

1. Distribuzione Normale:

- $Y \sim \mathcal{N}(\mu, \sigma^2)$
- Forma esponenziale: $\theta = \mu$, $\phi = \sigma^2$, $b(\theta) = \frac{\theta^2}{2}$, $c(y, \phi) = -\frac{y^2}{2\phi} - \frac{1}{2} \log(2\pi\phi)$.

2. Distribuzione Binomiale:

- $Y \sim \text{Binomiale}(n, p)$
- Forma esponenziale: $\theta = \log\left(\frac{p}{1-p}\right)$, $\phi = 1$, $b(\theta) = n \log(1 + e^\theta)$, $c(y, \phi) = \log\left(\binom{n}{y}\right)$.

3. Distribuzione Poisson:

- $Y \sim \text{Poisson}(\lambda)$
- Forma esponenziale: $\theta = \log(\lambda)$, $\phi = 1$, $b(\theta) = e^\theta$, $c(y, \phi) = -\log(y!)$.

Queste distribuzioni permettono di modellare variabili dipendenti Y che non sono normalmente distribuite, ampliando le applicazioni dei GLM rispetto ai modelli di regressione lineare tradizionali. La scelta della distribuzione appropriata dipende dalla natura dei dati e dal tipo di variabile dipendente che si sta modellando.

Nei modelli lineari generalizzati (GLM), la funzione di collegamento (*link function*) $g(\cdot)$ stabilisce una relazione tra il valore atteso della variabile dipendente Y , denotato come $E[Y|X]$, e una combinazione lineare delle variabili indipendenti. Questa relazione è espressa come:

$$g(E[Y|X]) = \eta = \alpha + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p$$

dove η è il predittore lineare, α è l'intercetta, e $\beta_1, \beta_2, \dots, \beta_p$ sono i coefficienti di regressione associati alle variabili indipendenti $X_1, X_2, \dots, X_p$.

La funzione di collegamento $g(\cdot)$ permette di modellare relazioni non lineari tra X e Y , trasformando il valore atteso di Y in modo che possa essere espresso come una combinazione lineare delle variabili indipendenti. Ad esempio, nel caso di una regressione logistica, la funzione di collegamento è il logit, definito come:

$$g(E[Y|X]) = \log\left(\frac{E[Y|X]}{1 - E[Y|X]}\right)$$

Questa trasformazione consente di modellare la probabilità che Y assuma un certo valore in funzione delle variabili indipendenti, pur mantenendo la linearità nei parametri. (James et al. 2013)

3.2 Modello Esplicativo

L'analisi inizia con GLM che modellano il conteggio totale di donazioni *per individuo* dal 2009 al 2023.

3.2.1 Quasi-Poisson

3.2.1.1 Teoria del quasi-Poisson

La teoria del quasi-Poisson è un'estensione del modello di regressione di Poisson utilizzata nei modelli lineari generalizzati (GLM) per gestire dati di conteggio che mostrano overdispersione. L'overdispersione si verifica quando la varianza dei dati è maggiore della media, una situazione che il modello di Poisson standard non può gestire poiché assume che la varianza sia uguale alla media.

Nel modello di Poisson standard, la distribuzione di Y è definita come:

$$Y \sim \text{Poisson}(\lambda)$$

dove λ è il parametro di intensità, e la varianza è uguale alla media: $\text{Var}(Y) = E[Y] = \lambda$.

Nel modello quasi-Poisson, invece, la varianza è proporzionale alla media, ma con un fattore di dispersione ϕ :

$$\text{Var}(Y) = \phi \cdot \lambda$$

dove ϕ è il parametro di dispersione che permette di modellare l'overdispersione. Quando $\phi > 1$, indica che c'è overdispersione nei dati.

La funzione di collegamento nel modello quasi-Poisson è la stessa del modello di Poisson, tipicamente il logaritmo naturale:

$$g(E[Y|X]) = \log(\lambda) = \eta = \alpha + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p$$

Il modello quasi-Poisson utilizza la stessa struttura lineare per il predittore η , ma permette una varianza maggiore rispetto alla media, fornendo una maggiore flessibilità nel modellare dati di conteggio che non seguono strettamente la distribuzione di Poisson.

3.2.1.2 Risultati

Dispersione stimata $\hat{\phi} = 6,7 \rightarrow$ over-dispersion marcata.

I coefficienti (estratti via `gtsummary`) mostrano:

- incremento di 1 anno di età $\rightarrow -0,7\%$ donazioni totali, con effetto quadratico che attenua il declino oltre i 55 anni;
- donor class = P («periodico / abituale») $+114\%$ rispetto a N.

3.2.2 Tweedie (*power* ~ 1.19)

3.2.2.1 Teoria della Tweedie

Il modello Tweedie è un tipo di modello lineare generalizzato (GLM) che gestisce dati che possono avere una distribuzione di probabilità con una combinazione di caratteristiche di distribuzioni di Poisson e gamma. È particolarmente utile per modellare dati che includono valori zero e continui positivi, come i dati di assicurazione che comprendono sinistri con importi variabili.

3.2.2.1.1 Caratteristiche del Modello Tweedie

Il modello Tweedie appartiene alla famiglia esponenziale e si caratterizza per avere una funzione di varianza della forma:

$$Var(Y) = \phi \cdot \mu^p$$

dove: - $\mu = E[Y]$ è il valore atteso, - ϕ è il parametro di dispersione, - p è il parametro di potenza che determina la forma della distribuzione.

3.2.2.1.2 Differenze rispetto al Quasi-Poisson

Il modello quasi-Poisson, come discusso in precedenza, assume che la varianza sia proporzionale alla media ($Var(Y) = \phi \cdot \lambda$), il che è utile per gestire l'overdispersione nei dati di conteggio.

Il modello Tweedie, invece, generalizza ulteriormente questa relazione introducendo il parametro di potenza p , che permette di modellare una gamma più ampia di distribuzioni: - $p = 1$: corrisponde al modello di Poisson, dove la varianza è uguale alla media. - $p = 2$: corrisponde al modello gamma, utilizzato per dati continui positivi. - $1 < p < 2$: rappresenta una distribuzione Tweedie, che combina caratteristiche di Poisson e gamma, utile per dati con valori zero e continui positivi. Verrà utilizzata successivamente.

3.2.2.1.3 Funzione di Collegamento

Come nei modelli GLM, il modello Tweedie utilizza una funzione di collegamento per stabilire la relazione tra il valore atteso e una combinazione lineare delle variabili indipendenti:

$$g(E[Y|X]) = \eta = \alpha + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p$$

La scelta della funzione di collegamento dipende dalla natura dei dati e dal valore del parametro di potenza p .

3.2.2.2 Risultati

Modello intermedio fra Poisson e Gamma, più robusto ai molti zeri.

L'AIC risulta inferiore del 4 % rispetto al Quasi-Poisson, confermando una migliore aderenza.

3.2.3 Gamma

3.2.3.1 Teoria della distribuzione Gamma

Il modello gamma è utilizzato per modellare variabili dipendenti che sono continue e positive. È particolarmente utile per dati che rappresentano tempi di attesa, costi, o altre misure che non possono assumere valori negativi.

3.2.3.1.1 Caratteristiche del Modello Gamma

La distribuzione gamma è parte della famiglia esponenziale e ha una funzione di densità di probabilità definita come:

$$f_Y(y|\alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} y^{\alpha-1} e^{-\beta y}$$

dove: - α è il parametro di forma, - β è il parametro di scala, - $\Gamma(\alpha)$ è la funzione gamma.

Nel contesto dei GLM, la varianza della distribuzione gamma è proporzionale al quadrato della media:

$$Var(Y) = \phi \cdot \mu^2$$

dove $\mu = E[Y]$ è il valore atteso e ϕ è il parametro di dispersione.

3.2.3.1.2 Funzione di Collegamento

Il modello gamma utilizza una funzione di collegamento per stabilire la relazione tra il valore atteso e una combinazione lineare delle variabili indipendenti. Una scelta comune per la funzione di collegamento nel modello gamma è il logaritmo naturale:

$$g(E[Y|X]) = \log(\mu) = \eta = \alpha + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p$$

Questa funzione di collegamento è appropriata perché garantisce che il valore atteso μ sia sempre positivo, riflettendo la natura dei dati modellati.

3.2.3.2 Risultati

La distribuzione Gamma, essendo una distribuzione continua e positiva, non è teoricamente ideale per modellare le donazioni di sangue, che sono dati discreti e limitati nell'intervallo $[0, 4]$. In teoria, una distribuzione discreta, come la binomiale, potrebbe essere più appropriata per rappresentare questo tipo di dati, ma nella sua applicazione ha dato scarsi risultati.

Infatti, la distribuzione Gamma offre una notevole flessibilità, a differenza della binomiale, grazie ai suoi iperparametri, che permettono di adattare la forma della distribuzione alle caratteristiche specifiche dei dati. Questa capacità di adattamento può risultare vantaggiosa in pratica, consentendo di ottenere un buon fit dei dati osservati, anche se la distribuzione non corrisponde perfettamente alla natura discreta delle donazioni di sangue.

Mentre la scelta della distribuzione Gamma potrebbe non essere teoricamente perfetta per dati discreti e limitati, la sua capacità di adattarsi bene ai dati grazie alla flessibilità dei suoi iperparametri la rende una scelta pratica in molti contesti.

3.3 Modello Predittivo

Obiettivo: prevedere *per ciascun donatore attivo nel 2022* il numero di donazioni 2023.

Dati di training: 2019-2022 → covariate laggate.

Target: y_{2023} .

3.3.1 Effetto Covid

Inserita dummy Covid (= 1 nei trimestri 2020-2022 in cui il centro trasfusionale ha operato su appuntamento)

Stima $\beta_{\text{covid}} = -0,29$ ($p < 0.001$): riduzione del 25 % sul tasso di donazione; l'interazione è positiva (+0,05) → l'impatto è mitigato nei donatori anziani.

3.3.2 Modello finale

4 Bayesians Hidden Markov Models

4.1 Accenni di Teoria

4.1.1 Processo Markoviano

Un processo stocastico è una collezione di variabili aleatorie indicizzate da un parametro, tipicamente il tempo, che può essere continuo o discreto ma con la condizione che sia equidistante. Le variabili aleatorie possono essere continue o discrete e possono essere correlate tra loro. Questa dipendenza caratterizza alcune delle proprietà che il processo può assumere come la stazionarietà, l'indipendenza o la correlazione. Queste proprietà possono definire categorie di processi stocastici, ad esempio i processi di Poisson sono caratterizzati da eventi che si verificano in modo indipendente e i processi stazionari sono caratterizzati da proprietà statiche, che non cambiano nel tempo.

Il processo markoviano è un caso specifico dei processi stocastici, e in questo caso la proprietà principale è che lo stato futuro dipende solamente dal suo presente e non dal passato. L'ipotesi assuntiva è molto forte e permette di semplificare drasticamente un modello di serie storiche. Infatti non servirà più osservare l'intero passato per predire il futuro, ma basterà appena avere le informazioni sullo stato precedente. Ciò si basa su proprietà base della probabilità, nel caso di un processo markoviano di primo ordine, l'osservazione successiva dipenderà solamente dalla precedente:

! Importante

Sia $\{X_t\} \quad t \geq 1$ un processo stocastico, allora $\{X_t\}$ si definisce processo markoviano di ordine 1 se e solo se

$$Pr(X_t|X_{t-1}, \dots, X_1) = Pr(X_t|X_{t-1}) \quad t \geq 2$$

Le catene markoviane sono costituite da altri due elementi: - la matrice di transizione: ovvero una matrice contenente le probabilità di transitare da uno stato i a uno stato j , $a_{ij} = Pr(X_t = j|X_{t-1} = i)$, $t \geq 2$, $i, j \in \{1, \dots, L\}$; - la probabilità degli stati iniziali, π_i , che indica la probabilità che la variabile aleatoria al tempo 1 appartenga allo stato i , e quindi $\pi_i = Pr(X_1 = i)$, $i \in \{1, \dots, L\}$.

Il processo markoviano sarà stazionario se la matrice di transizione rimarrà costante nel tempo.

Una catena di Markov potrà essere rappresentata solamente dal vettore di probabilità iniziali, π , e dalla matrice di transizione, $\mathbf{A}$, e dall'insieme dei possibili stati occupabili Z ; denotando il processo così: $\text{MC}(\pi, (\mathbf{A}), Z)$.

4.2

4.2.1 HMM

Catena di Markov nascosta z_t con emissioni y_t .

4.2.2 Modelli Bayesiani

Dirichlet per π e $\mathbf{A}$, Gamma per λ : conjugate $\Rightarrow$ expectations analitiche.

4.2.3 Variational Inference

`TraceEnum_ELBO`: integra esattamente le variabili discrete, ottimizza quelle continue tramite SVI.

4.2.4 Algoritmo Viterbi

4.3 Scelta del Numero di Stati Latenti

- Cross-validation ELBO + held-out LL + BIC su $K = 2 \dots 6$.
- Elbow a $K = 4$ per log-likelihood, ma BIC penalizza ($\Delta < 2$) $\rightarrow$ si adotta $K = 3$ per interpretabilità.

4.4 Il Modello

Stati:

Stato	λ (donazioni/anno)	interpretazione
0	0.01	non-donatore / «dormiente»
1	0.80	saltuario
2	2.4	abituale

4.5 Diagnostiche

- *Switch-rate* 23 % $\rightarrow$ la maggior parte dei donatori segue traiettorie stabili.
- Posterior predictive check: RMSE su conteggi annuali 0,39 (vs 0,65 del GLM).

4.6 Previsioni

5 Dashboard

6 Dashboard

6.1 Motivazione

Conoscere in anticipo il rischio di under-supply consente di pianificare:

- campagne di reclutamento mirate per fasce di età;
- campagne di incoraggiamento per utenti specifici;

6.2 Sviluppo

- Front-end: **Quarto** + **Shiny**.
- Back-end: modelli salvati in formato `torch.script` / `.rds`, caricati on-demand.

7 Conclusioni

7.1 Risultati

7.2 Idee per il Futuro

- **Hierarchical HMM** per distinguere tipologia di emocomponenti (sangue intero, plasma, piastrine).

Bordandini, Paola. 2025. «Geografie del capitale sociale. Trent'anni di senso civico in Italia». Riccardo Prandini. <https://cris.unibo.it/retrieve/ee59ddb4-bdeb-4be5-8d2e-e70467252248/Donazioni%20di%20sangue.pdf>.

James, Gareth, Daniela Witten, Trevor Hastie, e Robert Tibshirani. 2013. *An Introduction to Statistical Learning*. Springer.

Pati, Ilaria, Claudio Velati, Carlo Mengoli, Massimo Franchini, Francesca Masiello, Giuseppe Marano, Eva Veropalumbo, et al. 2021. «A forecasting model to estimate the drop in blood supplies during the SARS-CoV-2 pandemic in Italy». *Transfusion Medicine* 31 (marzo): 200–205. <https://doi.org/10.1111/tme.12764>.