

UNITS

Modellazione statistica delle donazioni di sangue nella provincia di Trieste

Dai GLM agli Hidden Markov Models: un quadro predittivo per la
pianificazione trasfusionale



ERIK DE LUCA

A.A. 2024/2025

link utili: <https://www.centronazionalesangue.it/> https://www.centronazionalesangue.it/wp-content/uploads/2025/02/1-ricerca-collaboratori-24_02_2025.pdf

Introduzione

L’obiettivo di questa tesi è proporre — e validare empiricamente — un framework statistico per la previsione delle donazioni di sangue nel territorio Giuliano-Isontino, con orizzonte annuale.

La scelta di concentrare l’analisi sulla provincia di Trieste è motivata da tre fattori:

1. **Alta densità di donatori rispetto alla popolazione residente:** il territorio triestino è storicamente virtuoso nella raccolta di sangue; ciò rende disponibili serie temporali lunghe e relativamente complete.
2. **Stabilità del bacino d’utenza:** la popolazione residente ha oscillazioni demografiche contenute, riducendo la variabilità “esterna” dovuta a migrazioni massicce. A differenza di grandi città, come Milano e Roma dove i flussi migratori sono hanno un impatto maggiore.
3. **Accesso a dati granulari:** l’ASUGI ha messo a disposizione un estratto anonimo dei registri donatori 2009-2023 che, pur privo di variabili sensibili, contiene informazioni anagrafiche e cronologia donativa sufficienti per la modellazione.

Nella pratica quotidiana i centri trasfusionali devono rispondere alla domanda clinica garantendo un buffer di scorte: sovrastimare i lotti in scadenza comporta costi di smaltimento, mentre sottostimare la raccolta può generare situazioni critiche con rinvii di interventi chirurgici programmati.

Pertanto, è cruciale disporre di **strumenti predittivi** che stimino:

- la probabilità che un donatore torni a donare l’anno successivo;
- la distribuzione del numero di donazioni attese per singolo individuo;
- i profili latenti di comportamento (frequente, saltuario, non-donatore, ecc.) e la loro evoluzione nel tempo.

A fronte di tali esigenze la tesi si articola in due nuclei metodologici:

1. **Generalized Linear Models** (GLM) per stimare il numero *cumulato* di donazioni nell’orizzonte storico, con diverse famiglie di distribuzione (quasi-Poisson, Tweedie, Gamma).
2. **Hidden Markov Models bayesiani** con covariate, in cui il numero di donazioni annue è trattato come emissione di una variabile di stato latente.

Il fitting è condotto mediante Variational Inference (Pyro), consentendo di gestire milioni di osservazioni con tempi computazionali compatibili al problema.

A corredo dei modelli è stata sviluppata una **dashboard interattiva Quarto + Shiny** che consente al personale medico di:

- filtrare la popolazione (età, genere, anno di prima donazione, ecc.);
- visualizzare la probabilità di transizione fra stati latenti;

I Dati

In Italia possono donare sangue le persone di età compresa tra i 18 e i 65 anni, con un peso corporeo superiore ai 50 kg e in buono stato di salute. Gli uomini e le donne non in età fertile possono donare sangue intero ogni 3 mesi, mentre le donne in età fertile possono farlo 2 volte l'anno.

La donazione di sangue nel contesto italiano è il frutto di un sistema dove stakeholder del settore pubblico (regioni, centri ospedalieri), privato (associazioni non profit) e cittadini contribuiscono attivamente al buon esito di questo processo (Guglielmetti Mugion et al., 2021). La creazione del Centro Nazionale Sangue (CNS) e del Registro nazionale del sangue nel 2007 ha trasformato l'assetto organizzativo della donazione del sangue in Italia. Il CNS è stato istituito con Decreto del Ministro della Salute del 26 aprile 2007 e ha iniziato il suo mandato il 1° agosto dello stesso anno. Il CNS svolge funzioni di coordinamento e controllo tecnico-scientifico del sistema trasfusionale nazionale nelle materie disciplinate dalla legge n. 219 del 21 ottobre 2005 “Nuova disciplina delle attività trasfusionali e della produzione nazionale degli emoderivati” e dai decreti di trasposizione delle direttive europee. All'interno di tale sistema sono presenti le Strutture Regionali di Coordinamento per le attività trasfusionali (SRC). Le SRC sono strutture tecnico-organizzative delle Regioni e Province Autonome che garantiscono il supporto alla programmazione nazionale in materia di attività trasfusionali e il coordinamento e controllo tecnico-scientifico della rete trasfusionale regionale, in sinergia con il Centro Nazionale Sangue. Queste strutture regionali, anche definite Centri Regionali Sangue, detengono la responsabilità della raccolta e gestione delle donazioni di sangue a livello regionale.

Nel corso degli anni, il Ministero della Salute ha visto un significativo supporto dalle associazioni attive nel campo delle donazioni, come AVIS (Associazioni Volontari Italiani Sangue), FRATRES (Consociazione Nazionale dei Gruppi Donatori di Sangue Fratres delle Misericordie d'Italia), FIDAS (Federazione Italiana Associazioni Donatori di Sangue), Croce Rossa Italiana. Queste organizzazioni svolgono un ruolo cruciale nel promuovere attivamente la pratica della donazione del sangue: sebbene la decisione di donare sia una scelta individuale, è infatti importante sottolineare il ruolo essenziale che esse svolgono nell'informare e nel fungere da ponte tra le istituzioni (scuole incluse) e i cittadini. La pratica del dono del sangue, peraltro, produce capitale sociale non solo per il dono di una parte di sé in quanto tale, ma anche grazie alla partecipazione sociale all'interno delle organizzazioni che la promuovono.

La letteratura riguardante il dono nel sangue nel contesto italiano si è concentrata principalmente sui donatori e sulle motivazioni al dono. Molte delle ricerche sono state svolte in collaborazione con l'AVIS, probabilmente perché la raccolta di informazioni riguardanti le unità di sangue donate si è sistematizzata a livello nazionale solo dal 2007 con l'istituzione del CNS e la creazione del registro nazionale sangue, come descritto poc'anzi. Le ricerche hanno sovente utilizzato dati raccolti intervistando i donatori (sia attraverso strumenti standardizzati, sia con approcci di tipo qualitativo). Nei prossimi paragrafi utilizzeremo i dati sulle donazioni di sangue a livello territoriale, ma prima di entrare nel dettaglio sulle differenze geografiche delle donazioni di sangue pare opportuna una sintetica ricognizione sui principali aspetti emergenti da tali ricerche condotte nel contesto italiano.

Un'analisi approfondita condotta da Lacetera e Macis (2013) sui dati AVIS relativi al periodo 1983-2006, focalizzata su una città del centro-nord Italia, ha quantificato l'impatto della Legge 584 del 1967, che ha stabilito il riconoscimento del diritto a una giornata di riposo dal lavoro e alla piena retribuzione al donatore di sangue, sulle pratiche di donazione. Lo studio ha rilevato che l'applicazione di tale normativa ha indotto i donatori a effettuare, in media, una donazione

aggiuntiva all'anno. Attraverso un'analisi comparativa delle frequenze di donazione associate ai diversi stati occupazionali assunti dal medesimo individuo, i ricercatori hanno evidenziato una correlazione significativa tra l'occupazione e la propensione alla donazione.

I risultati hanno dimostrato che, in media, quando un individuo è occupato e quindi idoneo a beneficiare dell'incentivo del giorno di riposo retribuito, la frequenza annuale delle donazioni aumenta di circa un'unità rispetto ai periodi di non occupazione.

La decisione di donare sangue è fortemente influenzata da fattori personali e sociali. Una ricerca condotta a Bergamo nel 2006 (Bani, Strepparava, 2011) ha mostrato che il 50% dei donatori è stato motivato dal confronto con amici e familiari, ma anche l'aver ricevuto trasfusioni o conoscere qualcuno che ha beneficiato di una trasfusione hanno avuto un impatto significativo, aumentando la frequenza delle donazioni e la propensione a persuadere altri a donare. Questi risultati evidenziano l'importanza delle relazioni personali e delle esperienze dirette nella promozione della donazione di sangue, confermando il forte legame emotivo e sociale che spinge le persone a donare.

Anche il lavoro delle associazioni, come ricordato, è fondamentale. Esse contribuiscono all'incremento di capitale sociale sia costruendo relazioni con le istituzioni locali, sia creando partecipazione e attivazione attraverso diverse iniziative che mirano allo sviluppo di senso di comunità e appartenenza (Saturni, 2013).

I giovani che partecipano all'AVIS (Bassi et al., 2024), percepiscono l'associazione non solo come un'opportunità per donare il sangue, ma anche come un punto di riferimento fondamentale per la comunità. All'interno della ricerca di Bassi e colleghi gli intervistati sottolineano il ruolo dell'AVIS come infrastruttura sociale capace di promuovere la coesione e l'inclusione. Essi vedono nel volontariato un'occasione per tessere relazioni, costruire reti e contribuire attivamente alla vita della comunità, confermando così l'importanza delle associazioni come presidi territoriali e promotori del capitale sociale.

Fonte ed Elaborazione

I dati provengono dall'estrazione e anonimizzazione di dati provenienti dal data warehouse dell'Azienda Sanitaria Universitaria Giuliano Isontina (ASUGI). Il dataset primario proviene dal sistema informativo dei centri trasfusionali dell'ASUGI e contiene, per ciascun donatore:

campo	descrizione
<code>unique_number</code>	identificativo anonimo del donatore
<code>gender</code>	M/F
<code>birth_year</code>	anno di nascita
<code>first_donation_year</code>	anno della prima donazione registrata
<code>donation_type</code>	categoria (SANGUE, PLASMA, PIASTRINE, ...)
<code>donor_class</code>	classificazione sanitaria (P = periodico, N = nuovo, C = convalescente, ...)
<code>y_2009 ... y_2023</code>	numero di donazioni effettuate in ciascun anno

Pulizia e controlli principali:

- rimozione record duplicati (`janitor::get_dupes`);

- sostituzione di NA con 0 nei conteggi annuali;
- derivazione di età = `year - birth_year` e classi d'età quinquennali;
- standardizzazione (z-score) di `birth_year` e `age` per facilitare la convergenza dell'ottimizzatore nei modelli bayesiani;
- creazione di **due matrici di covariate**:
 - x^π (fisse per donatore) $\rightarrow$ birth year norm, gender;
 - x_t^A (tempo-varianti) $\rightarrow$ age norm, dummy Covid (=1 per 2020-22).

Analisi Preliminare

- **268 530** record di donazioni, **36 625** partite di donatori sangue.
- Distribuzione fortemente asimmetrica: il 73 % dei donatori effettua 1-2 prelievi/anno, solo l'1 % arriva a 4.
- Trend 2009-2019 crescente (+8 %), brusco calo 2020 (-22 %) per effetto lockdown, graduale recupero 2021-23.
- Moda età 46 - 55 anni, con shift progressivo verso classi d'età superiori (invecchiamento della base, effetto *baby boom*).

Integrazione dei Dati

Stima dei Residenti Passati

L'ISTAT fornisce serie 2019-2023 per popolazione residente per età $\times$ sesso.

Per retro-proiettare la popolazione 2009-2018 si applica il **metodo “reverse life-table”**:

$$n_x^{y_i} = n_{x-(y_i-y_j)}^{y_j} \frac{l_x}{l_{x-(y_i-y_j)}},$$

dove l_x è il sopravvissuto all'età x nella tavola di mortalità italiane SIM/SIF 02.

Ipotesi: flussi migratori netti costanti e trascurabili nell'intervallo 2009-2019.

Unione dei Dati

La join tra donatori e residenti dà origine a indicatori di penetrazione:

$$\text{penetration}_{a,y,g} = \frac{\# \text{ donatori}(a, y, g)}{\text{residenti}(a, y, g)}, \quad g \in \{F, M\}, \quad a = \text{classe età}, \quad y.$$

Emerge come il tasso di donazione sia massimo nella fascia 30-39 anni (7 ‰) e diminuisca oltre i 60 anni (<2 ‰).

Risultati preliminari

Nel 2002, Cartocci riportava un valore di donazione pari a 384 ogni 10.000 abitanti; i dati in possesso di Paola Bordandini mostrano un incremento significativo, con un valore di 438 nel 2009 e un ulteriore aumento fino a 454 nel 2022. Dalle nostre stime, risulta che a Trieste, ...

Generalized Linear Models

L'analisi inizia con GLM che modellano il conteggio totale di donazioni *per individuo* dal 2009 al 2023.

Modello Esplicativo

Quasi-Poisson

Dispersione stimata $\hat{\phi} = 6,7$ -> over-dispersion marcata.

I coefficienti (estratti via `gtsummary`) mostrano:

- incremento di 1 anno di età -> -0,7 % donazioni totali, con effetto quadratico che attenua il declino oltre i 55 anni;
- donor class = P («periodico / abituale») +114 % rispetto a N.

Tweedie (*power* ~ 1.19)

Modello intermedio fra Poisson e Gamma, più robusto ai molti zeri.

L'AIC risulta inferiore del 4 % rispetto al Quasi-Poisson, confermando una migliore aderenza.

Gamma

Modello Predittivo

Obiettivo: prevedere *per ciascun donatore attivo nel 2022* il numero di donazioni 2023.

Dati di training: 2019-2022 → covariate laggate.

Target: `y_2023`.

Effetto Covid

Inserita dummy Covid (= 1 nei trimestri 2020-2022 in cui il centro trasfusionale ha operato su appuntamento)

Stima $\beta_{\text{covid}} = -0,29$ ($p < 0.001$): riduzione del 25 % sul tasso di donazione; l'interazione è positiva (+0,05) -> l'impatto è mitigato nei donatori anziani.

Modello finale

Bayesians Hidden Markov Models

Accenni di Teoria

HMM

Catena di Markov nascosta z_t con emissioni y_t .

Modelli Bayesiani

Dirichlet per π e A, Gamma per λ : conjugate $\Rightarrow$ expectations analitiche.

Variational Inference

TraceEnum_ELBO: integra esattamente le variabili discrete, ottimizza quelle continue tramite SVI.

Algoritmo Viterbi

Scelta del Numero di Stati Latenti

- Cross-validation ELBO + held-out LL + BIC su $K = 2 \dots 6$.
- Elbow a $K = 4$ per log-likelihood, ma BIC penalizza ($\Delta < 2$) $\rightarrow$ si adotta $K = 3$ per interpretabilità.

Il Modello

Stati:

Stato	λ (donazioni/anno)	interpretazione
0	0.01	non-donatore / «dormiente»
1	0.80	saltuario
2	2.4	abituale

Diagnostiche

- *Switch-rate* 23 % $\rightarrow$ la maggior parte dei donatori segue traiettorie stabili.
- Posterior predictive check: RMSE su conteggi annuali 0,39 (vs 0,65 del GLM).

Previsioni

Dashboard

Motivazione

Conoscere in anticipo il rischio di under-supply consente di pianificare:

- campagne di reclutamento mirate per fasce di età;
- campagne di incoraggiamento per utenti specifici;

Sviluppo

- Front-end: **Quarto** + **Shiny**.
 - Back-end: modelli salvati in formato `torch.script` / `.rds`, caricati on-demand.
-

Conclusioni

Risultati

Idee per il Futuro

- **Hierarchical HMM** per distinguere tipologia di emocomponenti (sangue intero, plasma, piastrine).