

Modellazione statistica delle donazioni di sangue nella provincia di Trieste

Modelli markoviani a stati nascosti integrati da modelli lineari generalizzati con un approccio bayesiano

Candidato Erik De Luca  Relatore Leonardo Egidi 

Definizione del Problema

Domanda

Come possiamo predire le **future donazioni** dei donatori e il loro **comportamento** basandoci sulle osservazioni passate di ciascun individuo e le sue informazioni sociodemografiche?

Scopo

- **Costruire** un modello per predire la propensione alla donazioni agli anni successivi
- **Scoprire** comportamenti latenti dei profili e pattern comuni di donazione
- **Quantificare** l'impatto delle informazioni sociodemografiche e di shock temporali (COVID-19)


Dati

I dati in nostro possesso

- Un panel di oltre 9.000 donatori a Trieste
- Il conteggio del numero di donazioni annue (0–4 per anno), nel periodo 2009–2023

Da dove vengono

- Centro trasfusionale dell'ASUGI
- Dati anonimizzati
- Informazioni disponibili: genere e anno di nascita



Previsione del numero totale di donazioni per individuo

Modello GLM

Distribuzione scelta: Poisson troncata


Ideale per variabili che rappresentano conteggi **strettamente positivi**.

Il modello è analogo a un GLM (*GLM-like*).¹

Adatto quando gli **zeri** sono strutturalmente **assenti** nel campione.

$$\Pr(Y = y \mid Y > 0, \mu) = \frac{e^{-\mu} \mu^y / y!}{1 - e^{-\mu}}, \quad y = 1, 2, \dots$$

Coefficienti del modello di Poisson troncato




Modello Markoviano a Stati Nascosti



Definizione del modello

Diagramma della struttura di un modello markoviano a stati latenti con a priori bayesiane ed un modello di regressione lineare sulle emissioni




Scelta del numero degli stati nascosti

Per la scelta del numero di stati latenti viene utilizzato il **Bayesian Information Criterion**:



$$\text{BIC} = k \ln(n) - 2 \ln(\hat{L}) \quad \text{BIC-like} = \ln(\hat{L}) - \frac{1}{2} k \ln(n)$$

Il numero di stati latenti scelto è di **3**.




Risultati: occupazione degli stati iniziali

- Gran parte dei donatori inizia nello stato di “non-donatore”
- I donatori più giovani e le donne hanno una probabilità maggiore di iniziare dallo stato di “non-donatore”
- Dei donatori più anziani quasi il 60% sono “donatori frequenti”
- Risultato coerente con il completamento longitudinale delle non-donazioni
- Una distribuzione a priori asimmetrica per garantire consistenza nelle etichette: $\pi_{\text{base}} \sim \text{Dirichlet}(\alpha_{\pi})$



Risultati: matrice di transizione

- I donatori rimangono abbastanza **stabili** nei loro stati (>80%)
- Dallo stato di “non-donatore” si passa a “donatore occasionale” e “donatore frequente” (>15%)
- Dallo stato di “donatore occasionale” si passa a “non-donatore”
- Dallo stato di “donatore frequente” si passa allo stato di “donatore occasionale”
- Sono state valutate **a priori** non informative e informative “diagonali”: $A_{\text{base}}[k, \cdot] \sim \text{Dirichlet}(\alpha_{A_k})$




Coefficienti della matrice di transizione

- $0 \rightarrow 0$: La probabilità di rimanere nello stato “non-donatore” decresce all’aumentare dell’età, ad eccezione della fascia +65¹
- Probabilità maggiori nelle transizioni $1 \rightarrow 0$ e $2 \rightarrow 1$ (decremento di numero di donazioni annue) nella fasce d’età più alte

Effetto COVID-19:


- Diminuzione delle probabilità nelle transizioni a “non-donatore” ($0 \rightarrow 0$, $1 \rightarrow 0$ e $2 \rightarrow 0$)
- Incremento delle probabilità nelle transizioni a “donatore occasionale” ($0 \rightarrow 1$ e $1 \rightarrow 1$)
- Incremento delle probabilità di transizione da “donatore frequente” a “donatore occasionale” ($2 \rightarrow 1$)



W_A - transition slopes



Coefficienti dei GLM



Algoritmo Viterbi

Obiettivo: Ottenere gli stati più probabili per ogni anno e per ogni donatore.

$z_{1:T}^*$ si ottiene per programmazione dinamica, con un passo base e un passo iterativo.

1. **Inizializzazione:** si ricavano le probabilità per stato al tempo iniziale.

$$\delta_1(k) = \log \pi_k(x^\pi) + \log \Pr(y_1 \mid z_1=k),$$


2. **Forward:** Ricorsione per $t = 2, \dots, T$ cercando il massimo della probabilità di stare nello stato precedente, k , sommato alla probabilità di spostarsi al tempo t dallo stato k allo stato j . Successivamente viene sommata la log-probabilità di emissione.

$$\delta_t(j) = \max_k \left\{ \delta_{t-1}(k) + \log A_{k \rightarrow j}(x_t^A) \right\} + \log \Pr(y_t \mid z_t=j),$$

$$\psi_t(j) = \arg \max_k \left\{ \delta_{t-1}(k) + \log A_{k \rightarrow j}(x_t^A) \right\}$$


3. **Backtracking:** cercare l'argomento che massimizza la funzione δ .

$$z_T^* = \arg \max_j \delta_T(j), \quad z_{t-1}^* = \psi_t(z_t^*) \quad (t = T, \dots, 2)$$





Occupazioni degli stati per anno


State occupancy over time




Esempio di predizione




Altri esempi




Contrazione delle donazioni



Donatore frequente



Donatore recente




Donatore recente

Confronto con un GLM

- Come benchmark è stato utilizzato un GLM Poisson con le medesime covariate: in questo modo l'aumento di performance è attribuibile alla componente latente
- Suddivisione del **dataset** di allenamento e di test **stratificato** per genere e fascia d'età
- Come metrica di confronto è stata scelta l'**accuracy**:

$$\text{Accuracy} = \frac{1}{N} \sum_{n=1}^N \mathbf{I}\{\text{round}(\hat{y}_n) = y_n\},$$


- Per il punto di previsione per il modello HMM-GLM sono stati usati **due metodi** distinti:
 - considereremo la mistura sugli stati
 - selezioneremo solo lo stato più probabile in $T+1$ e applicheremo il GLM di quello stato




Mappe di calore sulla frequenza degli errori per i modelli testati

Confronto con un GLM


Distribuzione percentuale errori GLM



Distribuzione percentuale errori HMM-GLM multi-state



Distribuzione percentuale errori HMM-GLM one-state



- Il modello HMM-GLM ottiene un'accuracy superiore al GLM (42% vs 28%)
- Dal HMM-GLM predetto sul solo stato più probabile emerge una forte massa in 0 (predizione esatta) e, a seguire, in -1 e -2 (sottostima), mostrando una **forte asimmetria** degli errori
- Il modello HMM-GLM che, invece, considera tutti possibili stati futuri e calcola una predizione pesata su di essi, si ottiene un'accuracy leggermente minore ma una **simmetria maggiore** e l'intervallo $[-1, 1]$ contiene all'incirca l'**80%** degli errori
- La maggior parte degli errori del GLM è tra -1 e 1 con dispersione più simmetrica

Conclusioni

Punti di forza

- Dataset pulito e con un alto numero di osservazioni in confronto con il numero di covariate disponibili
- Il modello esegue un **raggruppamento dinamico** per ciascun anno: adattandosi al complesso e mutabile comportamento umano
- Il modello è riuscito a “far parlare” le variabili, svelando **pattern nascosti**, più complessi e difficilmente ottenibili

Criticità riscontrate

- **Mancanza di informazioni** socio-demografiche sui donatori
- Si è provato ad integrare covariate, tramite i dati forniti dall'ISTAT ma senza successo
- Lo studio è stato limitato **unicamente** alle **donazioni di sangue**, scartando in principio gli altri tipi di donazione, come il plasma.
- I **donatori** sono stati **filtrati**, prendendo solo donatori compresi tra i 18 e i 70 anni d'età, ovvero in età donativa.

Idee per il futuro

- **Integrazione di ulteriori covariate**, come l'informazione se il donatore avesse in passato effettuato altri tipi di donazione. Ciò porterebbe probabilmente a un quarto stato: i “*super-donatori*”.
- Avendo a disposizione i dati di diversi centri trasfusionali, si potrebbe condurre un'**analisi su dati panel**, prendendo diverse informazioni sulla popolazione residente, come la percentuale di studenti, lavoratori, pensionati, ...
- L'introduzione di **prior** anche sulle altre componenti del modello, come i **coefficienti delle emissioni**. Questa parte, però, richiederebbe anche una revisione dei successivi algoritmi implementati e usati per le diagnostiche del modello

Grazie dell'ascolto

"All models are wrong, but some are useful."

— George Box