

UNITS

Modellazione statistica delle donazioni di sangue nella provincia di Trieste

Dai GLM agli Hidden Markov Models: un quadro predittivo per la
pianificazione trasfusionale



ERIK DE LUCA

A.A. 2024/2025

Introduzione

L'obiettivo di questa tesi è proporre — e validare empiricamente — un framework statistico per la previsione delle donazioni di sangue nel territorio Giuliano-Isontino, con orizzonte annuale.

La scelta di concentrare l'analisi sulla provincia di Trieste è motivata da tre fattori:

1. **Alta densità di donatori rispetto alla popolazione residente:** il territorio triestino è storicamente virtuoso nella raccolta di sangue; ciò rende disponibili serie temporali lunghe e relativamente complete.
2. **Stabilità del bacino d'utenza:** la popolazione residente ha oscillazioni demografiche contenute, riducendo la variabilità “esterna” dovuta a migrazioni massicce.
3. **Accesso a dati granulari:** l'ASUGI ha messo a disposizione un estratto anonimo dei registri donatori 2009-2023 che, pur privo di variabili sensibili, contiene informazioni anagrafiche e cronologia donativa sufficienti per la modellazione.

Nella pratica quotidiana i centri trasfusionali devono rispondere alla domanda clinica garantendo un buffer di scorte: sovrastimare i lotti in scadenza comporta costi di smaltimento, mentre sottostimare la raccolta può generare situazioni critiche con rinvii di interventi chirurgici programmati.

Pertanto, è cruciale disporre di **strumenti predittivi** che stimino:

- la probabilità che un donatore torni a donare entro i prossimi m mesi;
- la distribuzione del numero di donazioni attese per singolo individuo;
- i profili latenti di comportamento (frequente, saltuario, non-donatore, ecc.) e la loro evoluzione nel tempo.

A fronte di tali esigenze la tesi si articola in due nuclei metodologici:

1. **Generalized Linear Models** (GLM) per stimare il numero *cumulato* di donazioni nell'orizzonte storico, con diverse famiglie di distribuzione (quasi-Poisson, Tweedie, Gamma).
2. **Hidden Markov Models bayesiani** con covariate, in cui il numero di donazioni annue è trattato come emissione di una variabile di stato latente.

Il fitting è condotto mediante Variational Inference (Pyro), consentendo di gestire milioni di osservazioni con tempi computazionali compatibili al problema.

A corredo dei modelli è stata sviluppata una **dashboard interattiva Quarto + Shiny** che consente al personale medico di:

- filtrare la popolazione (età, genere, anno di prima donazione, ecc.);
- visualizzare la probabilità di transizione fra stati latenti;

I Dati

Fonte ed Elaborazione

Il dataset primario proviene dal sistema informativo dei centri trasfusionali dell'ASUGI e contiene, per ciascun donatore:

campo	descrizione
<code>unique_number</code>	identificativo anonimo del donatore
<code>gender</code>	M/F
<code>birth_year</code>	anno di nascita
<code>first_donation_year</code>	anno della prima donazione registrata
<code>donation_type</code>	categoria (SANGUE, PLASMA, PIASTRINE, ...)
<code>donor_class</code>	classificazione sanitaria (P = periodico, N = nuovo, C = convalescente, ...)
<code>y_2009 ... y_2023</code>	numero di donazioni effettuate in ciascun anno

Pulizia e controlli principali:

- rimozione record duplicati (`janitor::get_dupes`);
- sostituzione di **NA** con 0 nei conteggi annuali;
- derivazione di $\text{età} = \text{year} - \text{birth_year}$ e classi d'età quinquennali;
- standardizzazione (z-score) di `birth_year` e `age` per facilitare la convergenza dell'ottimizzatore nei modelli bayesiani;
- creazione di **due matrici di covariate**:
 - x^π (fisse per donatore) $\rightarrow$ birth year norm, gender;
 - x_t^A (tempo-varianti) $\rightarrow$ age norm, dummy Covid (=1 per 2020-22).

Analisi Preliminare

- **268 530** record di donazioni, **36 625** partite di donatori sangue.
- Distribuzione fortemente asimmetrica: il 73 % dei donatori effettua 1-2 prelievi/anno, solo l'1 % arriva a 4.
- Trend 2009-2019 crescente (+8 %), brusco calo 2020 (-22 %) per effetto lockdown, graduale recupero 2021-23.
- Moda età 46 - 55 anni, con shift progressivo verso classi d'età superiori (invecchiamento della base, effetto *baby boom*).

Integrazione dei Dati

Stima dei Residenti Passati

L'ISTAT fornisce serie 2019-2023 per popolazione residente per età × sesso.

Per retro-proiettare la popolazione 2009-2018 si applica il **metodo “reverse life-table”**:

$$n_x^{y_i} = n_{x-(y_i-y_j)}^{y_j} \frac{l_x}{l_{x-(y_i-y_j)}},$$

dove l_x è il sopravvissuto all'età x nella tavola di mortalità italiane SIM/SIF 02.

Ipotesi: flussi migratori netti costanti e trascurabili nell'intervallo 2009-2019.

Unione dei Dati

La join tra donatori e residenti dà origine a indicatori di penetrazione:

$$\text{penetration}_{a,y,g} = \frac{\# \text{ donatori}(a, y, g)}{\text{residenti}(a, y, g)}, \quad g \in \{F, M\}, \quad a = \text{classe età}, \quad y.$$

Emerge come il tasso di donazione sia massimo nella fascia 30-39 anni (7 ‰) e diminuisca oltre i 60 anni (<2 ‰).

Generalized Linear Models

L'analisi inizia con GLM che modellano il conteggio totale di donazioni *per individuo* dal 2009 al 2023.

Modello Esplicativo

Quasi-Poisson

Dispersione stimata $\hat{\phi} = 6,7$ -> over-dispersion marcata.

I coefficienti (estratti via `gtsummary`) mostrano:

- incremento di 1 anno di età -> -0,7 % donazioni totali, con effetto quadratico che attenua il declino oltre i 55 anni;
- donor class = P («periodico / abituale») +114 % rispetto a N.

Tweedie (*power* ~ 1.19)

Modello intermedio fra Poisson e Gamma, più robusto ai molti zeri.

L'AIC risulta inferiore del 4 % rispetto al Quasi-Poisson, confermando una migliore aderenza.

Gamma

Modello Predittivo

Obiettivo: prevedere *per ciascun donatore attivo nel 2022* il numero di donazioni 2023.

Dati di training: 2019-2022 $\rightarrow$ covariate laggate.

Target: y_{2023} .

Effetto Covid

Inserita dummy Covid (= 1 nei trimestri 2020-2022 in cui il centro trasfusionale ha operato su appuntamento)

Stima $\beta_{\text{covid}} = -0,29$ ($p < 0.001$): riduzione del 25 % sul tasso di donazione; l'interazione è positiva (+0,05) $\rightarrow$ l'impatto è mitigato nei donatori anziani.

Modello finale

Bayesians Hidden Markov Models

Accenni di Teoria

HMM

Catena di Markov nascosta z_t con emissioni y_t .

Modelli Bayesiani

Dirichlet per π e A, Gamma per λ : conjugate $\Rightarrow$ expectations analitiche.

Variational Inference

TraceEnum_ELBO: integra esattamente le variabili discrete, ottimizza quelle continue tramite SVI.

Algoritmo Viterbi

Scelta del Numero di Stati Latenti

- Cross-validation ELBO + held-out LL + BIC su $K = 2 \dots 6$.
- Elbow a $K = 4$ per log-likelihood, ma BIC penalizza ($\Delta < 2$) $\rightarrow$ si adotta $K = 3$ per interpretabilità.

Il Modello

Stati:

Stato	λ (donazioni/anno)	interpretazione
0	0.01	non-donatore / «dormiente»
1	0.80	saltuario
2	2.4	abituale

Diagnostiche

- *Switch-rate* 23 % $\rightarrow$ la maggior parte dei donatori segue traiettorie stabili.
- Posterior predictive check: RMSE su conteggi annuali 0,39 (vs 0,65 del GLM).

Previsioni

Dashboard

Motivazione

Conoscere in anticipo il rischio di under-supply consente di pianificare:

- campagne di reclutamento mirate per fasce di età;
- campagne di incoraggiamento per utenti specifici;

Sviluppo

- Front-end: **Quarto** + **Shiny**.
 - Back-end: modelli salvati in formato `torch.script` / `.rds`, caricati on-demand.
-

Conclusioni

Risultati

Idee per il Futuro

- **Hierarchical HMM** per distinguere tipologia di emocomponenti (sangue intero, plasma, piastrine).